

基于机器学习与关联网络的古代玻璃成分分析

摘要

古代玻璃的化学成分是鉴别其类别与产地的重要依据，然而风化作用会改变原始成分，为定量分析带来挑战。本文基于一批古代玻璃制品的化学成分数据，建立了一套多层次的数学模型，以解决风化影响下的玻璃分类、成分预测与内在关联分析问题。研究综合运用了统计检验、机器学习、智能优化算法与复杂网络理论，为通过化学成分数据理解古代玻璃制品提供了系统性的分析方案。

对于问题一，我们采用**卡方检验**分析了表面风化与玻璃类型、纹饰及颜色的关联性，确认了它们之间存在统计学关联。通过对比风化前后样本的化学成分分布，发现风化主要导致高钾玻璃中的氧化钾与铅钡玻璃中的氧化铅和氧化钡流失。为预测风化前的成分，本文引入**地球化学领域的质量平衡分析理论**，构建了基于风化系数的预测模型，该模型在缺乏成对样本的情况下，能够有效恢复文物的原始化学成分。

对于问题二，为研究两大类玻璃的分类规律，我们分别构建了**线性与非线性支持向量机模型**。其中，非线性模型获得了 97.41% 的交叉验证准确率，我们引入**博弈论中的 SHAP 值**对其进行解释，而线性模型的结果则直接验证了氧化铅与氧化钾是分类的核心指标。在亚类划分中，我们依据**变异系数**筛选特征，并结合**层次聚类与轮廓系数**，确定铅钡玻璃存在两个亚类，高钾玻璃存在五个亚类。划分结果显示铅钡玻璃可分为高铅钡助熔剂型与高硅基质型，高钾玻璃的亚类则在多种成分上表现出不同特征。

对于问题三，我们构建了基于**改进遗传算法优化的支持向量机分类器 IGA-SVM**，以鉴别未知类别文物的所属类型。该模型通过智能化全局寻优确定最优超参数组合，避免了传统模型选择的局限性。应用此模型，我们完成了对全部未知样本的分类。为确保结果的可靠性，我们设计了基于**蒙特卡洛模拟**的数据扰动与基于**参数网格搜索**的模型扰动双重灵敏度分析，验证了分类结果对于数据测量误差和模型参数选择的高度稳健性。

对于问题四，为探寻不同类别玻璃配方的内在结构差异，我们构建了**化学成分关联网络**。为消除成分数据总和恒定带来的虚假相关，我们首先采用化学计量学中的**中心化对数比变换**对数据进行处理。随后利用**图套索算法**计算偏相关系数以构建网络，并应用**鲁汶算法**进行社群发现。网络分析结果表明，铅钡玻璃与高钾玻璃的化学成分关联结构存在显著不同，前者以二氧化硅和氧化铅为核心形成紧密社群，后者则结构较为分散，这些差异反映了两者在原料与烧制工艺上的区别。网络分析结果表明，铅钡玻璃与高钾玻璃的化学成分关联结构存在显著不同，前者以二氧化硅和氧化铅为核心形成紧密社群，后者则结构较为分散，这些差异反映了两者在原料与烧制工艺上的区别。

关键字：卡方检验 地球化学 质量平衡分析理论 SHAP 值 支持向量机 中心化对数比 图套索算法 鲁汶算法

一、问题背景

NIPT（无创产前检测）是一种现代产前筛查技术，它通过分析孕妇外周血中来自胎儿的游离 DNA 片段，评估胎儿患有染色体非整倍体疾病的风险^[1]。临床上重点关注三类由染色体数目异常引起的病症，分别为唐氏综合征、爱德华氏综合征与帕陶氏综合征，它们分别对应胎儿 21 号、18 号与 13 号染色体的异常^[2]。该检测的有效性依赖于胎儿性染色体浓度：男胎 Y 染色体浓度需达 4%^[3]，女胎 X 染色体浓度则需无异常。

检测时点的选择是影响检测有效性的一个重要变量。若检测时间过早，胎儿游离 DNA 浓度可能不足，这将导致检测结果无法保证准确性。反之，若检测时间过晚，则可能会延误后续的临床决策。根据临床经验，孕 12 周以内发现异常属于低风险，孕 13 至 27 周发现属于高风险^[4]，而孕 28 周以后发现则为极高风险。

临床实践常依据身体质量指数 BMI 对孕妇分组并推荐统一检测时点，但该方法因忽略年龄、孕情等个体差异，并非最优。因此，需建立数学模型对孕妇进行合理划分，确定各群体的最佳检测时点，以平衡检测可靠性并降低延迟发现的风险。




图 1 问题背景示意图

二、问题重述

问题一：分析胎儿染色体浓度与孕妇孕周数和身体质量指数等指标的相互关系，并建立相应的关系模型。

问题二：针对男胎孕妇，依据其身体质量指数进行分组，确定各组的最佳无创产前检测时点以使潜在风险最小，并分析检测误差造成的影响。

问题三：考虑身高，体重，年龄等多重因素与检测误差，根据男胎孕妇的身体质量指数进行分组，并给出每组的最佳无创产前检测时点，以最小化孕妇潜在风险并顾及 Y 染色体浓度达标比例。

问题四：建立女胎染色体异常的判定方法，运用 Z 值，GC 含量，读段数及身体质量指数等多种因素，以识别 21 号，18 号和 13 号染色体的非整倍体异常。

三、问题分析（需修改）

针对问题一，该问题涉及两个层面，其一是定性关系的判断，其二是定量规律的分析与预测。表面风化与玻璃类型、纹饰、颜色均为分类变量，它们之间的关联性分析适合采用非参数的卡方检验。风化对化学成分含量的影响则需要分组进行统计比较，通过观察含量分布的变化来识别规律。由于缺乏同一文物风化前后的成对数据，直接建立回归预测模型存在困难，因此分析的重点在于依据风化机理，构建一个基于平均变化率的风化系数模型，用以反推风化前的化学成分。

针对问题二，该问题需要从监督学习与无监督学习两个角度展开。高钾与铅钡玻璃的分类规律研究是一个典型的二分类问题，可以基于探索性数据分析发现的关键化学成分，构建支持向量机等分类模型，并对模型进行解释。

针对问题三，该问题是分类模型的实际应用与可靠性验证。分析的核心在于构建一个泛化能力强且稳健的分类器。这需要比较多种模型架构，并论证选择支持向量机的合理性。为使模型性能最优化，需要采用改进遗传算法等智能优化算法进行超参数寻优。最终的鉴别结果需要通过数据扰动和模型参数敏感性分析的双重检验，以证明其结论并非偶然，而是具有高度的可靠性。

针对问题四，该问题要求探寻不同类别玻璃内部化学成分的关联结构。由于玻璃成分数据具有总和恒定的特性，直接计算相关系数会产生误导，因此必须首先采用中心化对数比变换来消除此统计约束。直接计算相关系数会产生误导，因此必须首先采用中心化对数比变换来消除此统计约束。

全文框架如图 2 所示：



图 2 全文框架示意图

四、模型假设（需修改）

为保证模型构建的合理性与分析过程的严谨性，我们提出以下基本假设。

1. 所有用于分析的数据均为成分总和在百分之八十五至一百零五区间的有效数据。
2. 数据中的空白项表示该化学成分未被检测到其含量可视为零。
3. 同一类型玻璃的风化过程与化学成分变化规律具有统计上的一致性。
4. 文物的化学成分组合能够有效地区分高钾玻璃与铅钡玻璃两大类别。
5. 同一文物多个采样点的平均化学成分可以代表该文物的整体特征用于亚类划分。
6. 化学成分间的偏相关关系能够反映其在玻璃配方或制作工艺中的直接关联。

五、符号说明（需修改）

本文后续章节中所使用的主要数学符号及其说明如表所示。

表 1 符号说明表

符号	说明
$k_{t,j}$	t 类玻璃中 j 成分的风化系数
$\bar{C}_{t,j,\text{weathered}}$	t 类玻璃风化样本中 j 成分的平均含量
$\bar{C}_{t,j,\text{unweathered}}$	t 类玻璃未风化样本中 j 成分的平均含量
$C'_{\text{unweathered},j}$	某一样本风化前 j 成分的预测含量
$\mathbf{w}, b$	支持向量机分类超平面的法向量与位移项
C	支持向量机的正则化系数
γ	径向基核函数的参数
ξ_i	支持向量机的松弛变量
CV	变异系数，用于衡量数据的相对离散程度
$\text{clr}(\mathbf{x})$	对样本向量 $\mathbf{x}$ 进行中心化对数比变换
S	样本协方差矩阵
Θ	精度矩阵，即逆协方差矩阵
λ	图套索算法的正则化参数
$\rho_{ij \cdot \text{rest}}$	变量 i 和 j 之间的偏相关系数
λ	图套索算法的正则化参数
$\rho_{ij \cdot \text{rest}}$	变量 i 和 j 之间的偏相关系数

六、模型准备

为了后续模型的建立与求解，本文进行如下模型准备，即数据清洗、特征工程等。具体机制如图 3 所示。




图 3 模型准备机制

6.1 数据清洗

6.1.1 缺失值处理与数据整合

为简化数据集，我们移除了与建模任务无直接关联的序号列。随后，我们对数据集中各变量进行缺失值统计，发现末次月经时间列存在部分数据缺失。末次月经时间的主要功能为推算孕周，而数据集中已包含更为直接的检测孕周列，故将其移除。

为使原始特征能够用于定量分析，我们需要将其转化为标准的数值格式。对于纯数字格式的检测时间列，我们将其转换为标准的日期时间格式；对于文本格式的检测孕周列，我们转换为可计算的浮点数值，例如十二周加三天转化为 12.43 周。对于孕妇 BMI 指标列中的缺失值，我们利用同一条记录的身高与体重数据，依据身体质量指数的官方计算公式进行填充，该公式如下所示

$$BMI = \frac{Weight(kg)}{Height(m)^2} \quad (1)$$

与使用均值或中位数等统计量填充相比，利用已有数据进行计算能保持数据的真实性。




图 4 核心特征分布

完成基础清洗与计算后，数据集内核心特征的整体分布如图 4 所示。该图展示了孕妇年龄，孕妇 BMI 与检测孕周三个变量的分布状况。从图中可以看出样本的年龄主要集中在 25 至 35 岁之间，孕妇 BMI 分布的峰值位于 30 附近。检测孕周则在 12 至 25 周之间呈现多个峰值，表明了检测时间点的集中性。

根据题目说明，原始数据中存在一次采血多次检测的情况，这种情况造成了数据冗余。为消除此冗余并为每个样本建立唯一的检测记录，本文以孕妇代码与检测抽血次数的组合为标识，对重复的检测条目进行聚合处理。在聚合过程中，对于连续型测量指标，采用算术平均值以平滑单次测量的随机波动。对于分类性质的状态指标，则保留其初次记录的值。

该聚合过程的效果通过图 5 中的前后对比得以展示。左图显示在处理前，单个孕妇对应的所有样本的所有检测记录数从 1 条至 9 条不等，其中多数孕妇具有 3 至 6 条记录。经过聚合处理后，如右图所示，每位孕妇的有效检测次数范围缩小至 1 至 5 次，其中具有 4 次有效检测的孕妇数量最多。




图 5 数据整合效果对比

6.1.2 异常值处理

我们首先针对年龄，孕妇 BMI 与孕周这三个核心特征执行四分位距法检验。对于识别出的离群点，本文采用软标记方法，即在数据集中新增一列用以标记样本是否为离群点，而不直接删除样本记录。离群点可能代表了真实存在的极端生理状况或数据录入错误，采用软标记策略为后续建模提供了灵活性。图 6 展示了离群点分析的过程，图中每个子图的小提琴形状表示了数据的分布，红色的圆点则标记出被标准四分位距准则判定为离群点的样本。图中可见，年龄的离群点主要分布在 40 岁以上的高龄区间，孕妇 BMI 的离群点则同时出现在低于 20 的低值区域与高于 40 的高值区域，而孕周的离群点相对较少。

其次我们对 GC 含量进行质量控制。GC 含量是衡量测序质量的重要指标。处理过程结合了统计学检验与业务规则，先对 GC 含量列执行标准的 1.5 倍四分位距检验以识




图 6 IQR 离群点分析

别出所有统计学上的离群点。然后，仅将这些离群点中数值低于 40% 的样本从数据集中直接删除。此方法能够剔除那些不仅在统计上异常，且低于业务经验常规下限的低质量测序样本。图 7 展示了处理后的数据，其中直方图展示了 GC 含量的整体分布形态近似正态分布，频数在 0.400 处达到峰值，绝大多数样本的 GC 含量分布在 0.395 至 0.405 之间，分布集中，数据质量较高。




图 7 GC 含量离群点分析




图 8 染色体异常类型分布

6.2 特征工程

为了便于后续相关数学模型的建立与求解，针对类别型变量，我们进一步进行了数据量化。

针对不同问题,我们构建了相应的目标变量。对于男胎数据，依据题目定义的 4% 阈值，我们创建了“Y 浓度是否达标”的二元分类变量。对于女胎数据，则基于染色体的非整倍体列中空白即为无异常的定义，创建了“是否异常”以及各类异常的分类目标。图 8 展示了女胎样本中正常与各类异常样本的数量分布。图中可见正常样本数量为 488 例，而 18 号，13 号与 21 号染色体三体综合征的样本数量分别为 45 例，22 例与 13 例。正常样本远多于异常样本，表明这是一个数据不平衡问题。

考虑到问题四需要使用机器学习分类模型，我们仅针对女胎数据的所有数值型预测

特征应用了标准化处理。标准化将所有特征转换到同一尺度，其计算方法如下

$$z = \frac{x - \mu}{\sigma} \quad (2)$$

其中 x 为原始值， μ 为特征均值， σ 为特征标准差。此操作避免了模型的训练过程被原始读段数等具有极大数值范围的特征所主导，使模型能够更稳定地学习所有特征的贡献。男胎数据因主要用于回归和优化分析，保留其原始数值的物理意义更为重要，故不进行缩放。**??**展示了女胎数据中所有数值型预测变量在标准化处理前后的分布对比。每个子图呈现了同一特征在处理前后的分布形态，处理前各变量的分布中心与尺度范围各不相同，而经过标准化处理后，所有变量的分布均被调整至以 0 为中心，具有相似的尺度，这为后续机器学习模型的训练提供了同质化的输入。




图 9 所有数值特征标准化效果对比

此外，我们还构建了部分衍生特征。我们依据题目对风险的定义，创建了与孕周对应的风险等级特征。同时，为进行时序分析，还计算了每次检测距首次检测的天数。

七、问题一：关系模型的建立与求解

为识别影响男胎 Y 染色体浓度的主要因素并量化其作用，我们先构建最终数据集，再通过探索性分析与迭代建模建立能反映数据规律的关系模型。具体流程见 图 10。




图 10 关系模型的建立与求解流程

7.1 数据准备与探索性分析

本章的分析始于经过初步处理的男胎样本数据。为保证模型的稳健性，避免极端值对模型参数估计产生不当影响，我们对 Y 染色体浓度、孕妇 BMI、年龄与孕周四个核心变量应用了四分位距准则进行离群点检测。对于孕妇 BMI、年龄与孕周，我们直接使用了之前的软标记记录。在联合筛选过程中，任何在上述四个变量中至少存在一个离群点的样本记录均被移除。经过筛选，共 54 条记录被剔除，最终形成了包含 944 条高质量观测记录的分析数据集。该数据清洗过程的效果如图 11 所示，其中的蓝色部分和橙色部分分别对应了保留样本与剔除样本，而红色虚线标示了依据四分位距准则计算得出的离群点判断上边界。处理后的数据分布更为集中，减少了极端值可能带来的干扰。




图 11 Y 染色体浓度离群点剔除过程

在构建正式模型之前，我们先对变量间的关系进行了初步的可视化分析。为了展示 Y 染色体浓度与孕周（GW）及孕妇 BMI 之间的关系，我们绘制了散点图。在此基础上，我们进一步采用了局部加权散点平滑（LOESS）方法，在散点图上叠加了拟合曲线。LOESS 通过对每个数据点周围的局部数据子集进行加权多项式回归，能够捕捉并展示数据的局部趋势，而无需预设全局的函数形式。




图 12 Y 染色体浓度与孕周的散点关系




图 13 Y 染色体浓度与 BMI 的散点关系

如图 12 所示，Y 染色体浓度与孕周的关系的平滑曲线呈现出 S 型趋势，表明两者之间存在非线性关系。相比之下，图 13 中 Y 染色体浓度与孕妇 BMI 的散点分布则较为分散。

为对变量间的关联程度进行定量评估，我们还计算了两种相关性度量指标及其对应的统计显著性水平。

皮尔逊相关系数 r 用于衡量两个连续变量间线性关系的强度与方向。其取值范围为 -1 至 1，绝对值越接近 1 表示线性关系越强。计算公式为：

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (3)$$

其中 x_i 与 y_i 是第 i 对观测值， $\bar{x}$ 与 $\bar{y}$ 分别是两个变量的样本均值， n 是样本总数。皮尔逊 P 值用于检验这种线性相关的统计显著性，表示在原假设即两个变量无线性关系成立的条件下，获得当前或更极端 t 统计量的概率。它通过将相关系数 r 转换为 t 统计量来计算，公式如下：

$$t = r \sqrt{\frac{n-2}{1-r^2}} \quad (4)$$

斯皮尔曼相关系数 ρ 则用于度量变量间的单调关系，它不要求变量呈线性关系。该系数同样取值于 -1 至 1 之间。计算时先将原始数据转换为等级，再根据等级计算皮尔逊相关系数，其简化计算公式为：

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (5)$$

此处 d_i 是第 i 对观测值的等级之差。斯皮尔曼 P 值同样用于检验单调关系的显著性，其检验统计量的计算方式与皮尔逊 P 值的类似。

表 2 Y 染色体浓度与核心自变量的相关性分析

变量对	Pearson 相关系数 r	Pearson P 值	Spearman 相关系数 ρ	Spearman P 值
Y 浓度 vs 孕周	0.1087	0.0007	0.0851	0.0083
Y 浓度 vs BMI	-0.1531	0.0000	-0.1321	0.0000

相关性计算的结果如表 2 所示。所有 P 值均远小于 0.01，说明相关性在统计上是显著的。然而，相关系数的绝对值均较小，如 Y 染色体浓度与孕周的皮尔逊相关系数为 0.1087，与 BMI 的相关系数为 -0.1531。这些数值表明变量间的线性关系较弱。定量计算的结果与散点图可视化的结果相符，这进一步说明使用简单的线性模型可能无法充分捕捉变量间的动态关系。

7.2 关系模型的构建与择优

基于探索性分析的发现，本文构建了四种不同形式的模型来拟合 Y 染色体浓度与孕周及孕妇 BMI 之间的关系，并通过一系列统计指标对它们的性能进行比较，以选取最合适的模型。

7.2.1 模型构建

模型一为多元线性回归模型，作为后续比较的基准。其形式为：

$$Y_{ij} = \beta_0 + \beta_1 GW_{ij} + \beta_2 BMI_{ij} + e_{ij} \quad (6)$$

模型二为多元多项式回归模型，用以分析之前发现的非线性关系。其形式为：

$$Y_{ij} = \beta_0 + \sum_{k=1}^p \beta_k GW_{ij}^k + \sum_{l=1}^q \gamma_l BMI_{ij}^l + e_{ij} \quad (7)$$

模型三为广义线性模型，它通过对数连接函数处理可能的指数关系。其形式为：

$$g(E[Y_{ij}]) = \beta_0 + \beta_1 GW_{ij} + \beta_2 BMI_{ij} \quad (8)$$

其中 $g(\cdot)$ 为对数连接函数。

模型四为非线性混合效应模型。考虑到数据中包含同一孕妇的多次检测记录，孕妇个体间的生理差异可能对 Y 染色体浓度有影响，为解释这种个体异质性，本文引入了该

模型。该模型在固定效应的基础上，为每个孕妇个体设置了随机效应。其形式为：

$$\begin{aligned}
 Y_{ij} = & \underbrace{(\beta_0 + u_{0i})}_{\text{随机截距}} + \underbrace{\left((\beta_1 + u_{1i})GW_{ij} + \sum_{k=2}^p \beta_k GW_{ij}^k \right)}_{\text{孕周主效应 (含随机斜率)}} \\
 & + \underbrace{\left(\sum_{l=1}^q \gamma_l BMI_{ij}^l \right)}_{\text{BMI 主效应}} + \underbrace{\left(\sum_{k=1}^p \sum_{l=1}^q \delta_{kl} (GW_{ij}^k \cdot BMI_{ij}^l) \right)}_{\text{多指数交互效应}} + e_{ij}
 \end{aligned} \tag{9}$$

其中， Y_{ij} 表示第 i 位孕妇在第 j 次检测时的 Y 染色体浓度。 GW_{ij} 与 BMI_{ij} 是对应的孕周和身体质量指数。 β_0, β_k 与 γ_l 是固定效应系数，代表了样本总体的平均趋势。 u_{0i} 与 u_{1i} 是随机效应项，分别代表第 i 位孕妇的个体基线水平和对孕周影响的个体差异，它们服从均值为 0 的正态分布。 e_{ij} 是随机误差项。

7.2.2 模型性能评估准则

为在不同形式的模型中进行择优，本文包含多个维度的评估准则，分别从模型拟合度，复杂性惩罚，预测误差和变异解释度四个方面对模型进行评价。

对数似然值，记作 LL，是衡量模型拟合优度的基本指标。它表示在给定模型参数下，观测数据出现的概率的对数。较高的对数似然值说明模型能更好地拟合样本数据。对于一组独立同分布的样本，其计算公式为：

$$LL = \sum_{i=1}^n \ln(f(y_i|\theta)) \tag{10}$$

其中 y_i 是第 i 个观测值， $f(y_i|\theta)$ 是模型在参数 θ 下关于 y_i 的概率密度或概率质量函数， n 为样本量。

赤池信息准则 AIC 与贝叶斯信息准则 BIC 是基于信息论的模型选择标准。它们在对数似然值的基础上，对模型的参数数量施加惩罚，从而在拟合优度与模型简洁性之间进行权衡。数值较小的模型被认为是更优的选择。

$$AIC = 2k - 2LL \tag{11}$$

$$BIC = k \ln(n) - 2LL \tag{12}$$

在上述公式中， k 代表模型中待估参数的个数。BIC 对参数数量的惩罚项 $k \ln(n)$ 比 AIC 的惩罚项 $2k$ 更大，因此 BIC 倾向于选择更为简洁的模型。

均方根误差 RMSE 用于度量模型预测值与真实值之间的偏差大小。它的计算结果与因变量的单位相同，直观反映了模型的平均预测误差。RMSE 的数值越小，表明模型

的预测精度越高。其计算公式为：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

此处 y_i 是真实观测值， $\hat{y}_i$ 是模型对第 i 个样本的预测值。

决定系数 R^2 衡量的是模型对因变量方差的解释比例。其取值通常在 0 到 1 之间，越接近 1 说明自变量对因变量的解释能力越强，模型对数据的拟合程度越好。对于普通线性模型，其定义为：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (14)$$

公式中分子的部分是残差平方和，分母的部分是总平方和， $\bar{y}$ 是观测值的样本均值。

对于混合效应模型，决定系数的概念被进一步划分为边际决定系数与条件决定系数，它们分别量化了模型中固定效应部分以及整个模型对因变量变异的解释程度。

边际决定系数 $R_{marginal}^2$ 表示仅由模型中的固定效应解释的方差比例。它反映了群体平均趋势的解释能力。其计算公式为：

$$R_{marginal}^2 = \frac{\sigma_f^2}{\sigma_f^2 + \sigma_r^2 + \sigma_\epsilon^2} \quad (15)$$

在此公式中， σ_f^2 是固定效应预测值的方差， σ_r^2 是随机效应的方差， σ_ϵ^2 是模型残差的方差。

条件决定系数 $R_{conditional}^2$ 表示由固定效应和随机效应共同解释的方差比例。它反映了考虑个体差异后，整个模型的解释能力。其计算公式为：

$$R_{conditional}^2 = \frac{\sigma_f^2 + \sigma_r^2}{\sigma_f^2 + \sigma_r^2 + \sigma_\epsilon^2} \quad (16)$$

该指标在分子中加入了随机效应的方差 σ_r^2 ，因此其值总会大于或等于边际决定系数。这两个指标共同为混合效应模型的性能提供了更全面的评估。

7.3 模型评估结果

表3的评估结果显示，模型一与模型二的调整后决定系数均低于 0.04，说明仅考虑固定效应的线性和多项式模型对 Y 染色体浓度变异的解释能力有限。模型三的伪决定系数为负值，表明该模型的拟合效果差于基础的均值模型。

相比之下，模型四的各项指标均表现出优势。其对数似然值最高，AIC 与 BIC 值最低，说明该模型在拟合优度与模型复杂度之间取得了更好的平衡。模型四的均方根误差 RMSE 为 0.0096，远低于其他模型。该模型提供了两种决定系数，边际 R^2 为 0.4197，代

表 3 四种候选模型的评估指标对比

模型	对数似然值	AIC	BIC	RMSE	R^2
M1 线性回归	1999.22	-3992.43	-3977.82	0.0303	0.0377 ^a
M2 多项式回归	1999.61	-3991.23	-3971.75	0.0303	0.0375 ^a
M3 广义线性模型	2005.10	-4004.20	-6420.10	0.0303	-0.0107 ^b
M4 混合效应模型	2379.25	-4740.50	-4696.68	0.0096	边际: 0.4197, 条件: 0.9158

^a 调整后决定系数

^b 伪决定系数

表仅由固定效应即孕周和 BMI 所解释的变异比例。条件 R^2 为 0.9158，它代表由固定效应和随机效应共同解释的变异比例。这一数值说明，在考虑了孕妇的个体差异后，模型能够解释 Y 染色体浓度超过 91% 的变异。




图 14 线性模型与非线性混合效应模型拟合效果对比

图14对比了线性模型与非线性混合效应模型的拟合效果。混合效应模型捕捉到的趋势显然更能贴合数据的整体分布形态。综合各项指标，本文最终选择非线性混合效应模型来描述 Y 染色体浓度与母体指标的关系。

7.4 最终模型解析与显著性检验

在确定采用非线性混合效应模型后，本文通过似然比检验对其具体形式进行了优化。检验结果表明，在模型中加入孕周的二次项能提升模型拟合度，而更高阶的项或交互项则无显著改善。因此，最终确立的模型形式为：

$$\hat{Y}_{ij} = \underbrace{(-0.1135 + u_{0,i})}_{\text{个体基础水平}} + \underbrace{(0.0329 + u_{1,i})}_{\text{个体线性变化率}} \cdot GW_{ij} - 0.00190 \cdot GW_{ij}^2 + 0.0000389 \cdot GW_{ij}^3 - 3.378 \times 10^{-7} \cdot BMI_{ij}^3 \quad (17)$$

其中 Y_{ij} 为因变量， GW_{ij} 与 BMI_{ij} 为自变量， β 系列参数为固定效应系数， u 系列参数为随机效应项。为检验模型中各固定效应的统计显著性，本文对模型的参数估计结果进行分析。

模型参数的评估与检验涉及多个关键指标，它们共同为判断变量效应的显著性与模型的有效性提供依据。

首先是估计系数，记作 $\hat{\beta}$ 。它由模型拟合过程即受限最大似然法得到，其数值是通过最大化样本数据在给定模型结构下的似然函数来确定的。此系数代表了自变量每变化一个单位，对因变量产生的平均效应的量化估计。

其次是标准误差，记作 $SE(\hat{\beta})$ 。它是对估计系数 $\hat{\beta}$ 抽样分布标准差的估计，反映了估计值的精密度。标准误差的数值越小，表明参数估计的确定性越高。其计算源于模型参数的方差协方差矩阵的对角线元素：

$$SE(\hat{\beta}_k) = \sqrt{Var(\hat{\beta}_k)} \quad (18)$$

其中 $Var(\hat{\beta}_k)$ 表示第 k 个估计系数 $\hat{\beta}_k$ 的方差。

为进行假设检验，需要计算 z 统计量。该统计量衡量估计系数偏离原假设零值的标准误差倍数，其意义在于将估计系数的差异标准化，以便于进行统计推断。计算公式为：

$$z = \frac{\hat{\beta} - \beta_0}{SE(\hat{\beta})} \quad (19)$$

在此公式中， β_0 是原假设下的参数值，通常设为零以检验变量的效应是否显著。

根据 z 统计量可以计算出 P 值。它是在原假设即系数为零成立的前提下，观测到当前或更极端统计量的概率。 P 值越小，表明观测结果越不可能由随机抽样误差造成的，拒绝原假设的理由越充分。对于双侧检验，其计算公式为：

$$P = 2 \cdot \Phi(-|z|) \quad (20)$$

其中 Φ 是标准正态分布的累积分布函数， $|z|$ 是 z 统计量的绝对值。

最终模型的固定效应参数估计与检验结果如下表所示。

表 4 最终模型固定效应参数估计与检验

固定效应	估计系数	z 统计量	P 值
截距	-0.1135	-2.479	0.013
孕周	0.0329	4.162	<0.001
孕周二次项	-0.0019	-4.247	<0.001
孕周三次项	3.89e-05	4.772	<0.001
BMI 三次项	-3.38e-07	-1.800	0.072

表4的参数估计结果揭示了各变量对 Y 染色体浓度的具体影响。孕周的线性，二次项与三次项的 P 值均远小于 0.001，表明这些效应在统计上是极端显著的。这些系数共同作用，构成了 Y 染色体浓度随孕周变化的 S 型曲线关系。孕妇 BMI 三次项的 P 值为 0.072，处于统计学上的边缘显著水平，说明其对 Y 染色体浓度的影响相对微弱。

表 5 最终模型决定系数

指标	值
边际 R^2	0.4197
条件 R^2	0.9158

模型的決定系数分解结果为理解变异来源提供了定量证据，见表5。边际 R^2 为 0.4197，这表明由孕周和 BMI 构成的固定效应，即所有孕妇共有的普遍规律，能够解释 Y 染色体浓度总体变异的 41.97%。条件 R^2 的值为 0.9158，这意味着当模型同时考虑普遍规律和个体差异即随机效应后，其对总体变异的解释能力上升至 91.58%。

两者之差，即 91.58% 减去 41.97% 等于 49.61%，这部分变异由不可观测的孕妇个体特异性所解释。个体差异即随机效应的影响程度 49.61%，超过了所有可观测变量即固定效应的总和 41.97%。这一结果表明，个体差异是 Y 染色体浓度变异的主导因素。模型的方差成分进一步量化了这种差异，其中随机截距的方差为 1.627e-03，随机斜率的方差为 6.682e-06。

图15是最终模型结果的可视化呈现，是问题一的核心结论。图中的红色粗线代表了由固定效应决定的总体平均趋势，即所有孕妇共有的 S 型变化规律。大量的蓝色细虚线则代表了考虑随机效应后，每一位孕妇个体的实际拟合轨迹，直观展现了巨大的个体差异。

综合来看，Y 染色体浓度的变化遵循一个由孕周主导的 S 型非线性变化，这一趋势具有统计学意义。然而，该规律在不同孕妇间的表现存在显著的差异性，个体差异性是




图 15 最终模型揭示的总体趋势与个体差异

引起浓度变化的更主要来源。相比之下，孕妇的 BMI 在此模型中仅表现出边缘显著的微弱影响。

八、问题二：分组优化与 NIPT 时点决策模型

问题二要求为不同身体质量指数即 BMI 的男胎孕妇制定分组方案，并为各组确定唯一的最佳 NIPT 检测时点。该策略的目标是最小化全体孕妇的潜在风险总和。决策过程需要在两种风险之间权衡，一是过早检测可能因 Y 染色体浓度不达标而失败，二是过晚检测会缩短临床干预的有效时间。为处理此权衡问题，本文建立了一个包含孕妇分组与时点选择的双层决策模型。具体机制如图 16 所示。

8.1 风险量化与优化目标

模型顶层的优化目标为寻找最优的分组数量 K ，使所有组别按其人口比例加权的期望风险总和达到最小。总期望风险 $E[R_{total}]$ 的数学表达式为

$$\min_{K, \{t_i\}} E[R_{total}] = \sum_{i=1}^K \frac{n_i}{N} \cdot R_i^*(t_i^*) \quad (21)$$



图 16 问题二流程图

其中 N 为孕妇总数， n_i 为第 i 组的人数， $R_i^*(t_i^*)$ 是第 i 组在其最优检测时点 t_i^* 下的最小期望风险。对于任何分组 i ，其在特定检测时点 t_i 的总期望风险 $R_i(t_i)$ 由两部分构成

$$\min_{t_i} R_i(t_i) = R_{late}(t_i) + R_{fail}(t_i) \quad (22)$$

此处的 $R_{late}(t_i)$ 是因推迟检测累积的健康风险， $R_{fail}(t_i)$ 是因检测失败造成的机会成本风险。 $R_{late}(t_i)$ 随时间增加，而 $R_{fail}(t_i)$ 随时间减少。两者叠加形成的 $R_i(t_i)$ 总风险曲线上存在一个最小值点，该点对应的的时间即为最优检测时点。

8.2 风险函数的数学构建

为量化延迟检测的健康风险，依据题目描述的早、中、晚三个孕期风险等级，构建了一个分段函数。该函数通过线性和指数部分描述风险增长先缓后急的特征

$$R_{late}(t_i) = \begin{cases} \frac{2}{14}(t_i - 70) & \text{若 } 70 \leq t_i \leq 84 \\ 2 + \frac{4}{105}(t_i - 84) & \text{若 } 84 < t_i \leq 189 \\ 0.2225 \cdot e^{0.0243 \cdot t_i} & \text{若 } 189 < t_i \leq 210 \end{cases} \quad (23)$$

在此函数中， $R_{late}(t_i)$ 代表在第 t_i 天检测时，因延迟累积的健康风险值，自变量 t_i 为天数。

对于检测失败的风险，本文使用了微观经济学中的机会成本理论进行量化。选择在特定时点检测，若因 Y 染色体浓度不达标而失败，其后果是必须延后进行下一次检测。此延后构成一种机会成本，其代价是在等待重新检测期间，孕妇所承受的额外健康风险增量。因此，检测失败风险 $R_{fail}(t_i)$ 被定义为失败概率与失败所致机会成本的乘积

$$R_{fail}(t_i) = E[P_{fail,group}(t_i)] \times W(t_i) \times [R_{late}(t_i + \Delta t) - R_{late}(t_i)] \quad (24)$$

其中， $E[P_{fail,group}(t_i)]$ 是该分组在时点 t_i 的期望失败概率。 $W(t_i)$ 是随时间变化的价值

权重函数。 Δt 代表两次检测的时间间隔，本文设定为 14 天。最后的差值项是对机会成本的量化，表示因本次检测失败而被迫推迟 Δt 天后，带来的健康风险净增量。

时间价值权重 $W(t_i)$ 用以体现不同孕周决策价值的差异，其形式为一个反向逻辑斯谛函数

$$W(t_i) = 0.01728 + \frac{0.16344}{1 + e^{0.1(t_i - 154)}} \quad (25)$$

此函数中变量 t_i 为检测时点的天数，函数输出值 $W(t_i)$ 为该时点对应的决策价值权重。

8.3 失败概率的预测模型

为计算特定分组在特定时间的期望失败概率 $E[P_{fail,group}(t_i)]$ ，需要一个能够预测 Y 染色体浓度的数学模型。该模型需能反映群体趋势与个体差异。本文采用问题一建立的非线性混合效应模型进行预测。模型形式为

$$\hat{Y}_{ij} = (\beta_0 + u_{0,i}) + (\beta_1 + u_{1,i})GW_{ij} + \beta_2 GW_{ij}^2 + \beta_3 GW_{ij}^3 + \beta_4 BMI_{ij}^3 \quad (26)$$

其中， $\hat{Y}_{ij}$ 是对第 i 位孕妇在第 j 次检测时 Y 染色体浓度的预测值。参数 β_0 至 β_4 是固定效应系数，代表样本总体的平均变化规律。 $u_{0,i}$ 与 $u_{1,i}$ 是随机效应项，代表第 i 位孕妇的个体基线水平与孕周影响的个体差异。

基于此模型，可计算任一孕妇 i 在未来时间点 t 的失败概率。检测失败定义为 Y 染色体浓度低于百分之四的阈值。个体失败概率 $P_{fail,i}(t)$ 的计算用到模型的预测值 $\hat{Y}_i(t)$ 与模型残差的标准差 $\hat{\sigma}_\epsilon$ ，其计算式为

$$P_{fail,i}(t) = P(Y_i(t) < 0.04) = \Phi\left(\frac{0.04 - \hat{Y}_i(t)}{\hat{\sigma}_\epsilon}\right) \quad (27)$$

其中 $\Phi(\cdot)$ 是标准正态分布的累积分布函数。一个分组的整体期望失败概率，是该分组内所有个体失败概率的算术平均值

$$E[P_{fail,group}(t)] = \frac{1}{n_{group}} \sum_{i \in group} P_{fail,i}(t) \quad (28)$$

此处的 n_{group} 是该分组内的孕妇总人数。该计算方法将每位孕妇的个体特征都纳入考量，从而得到整个群体的风险评估。图 17 展示了混合效应模型为部分孕妇生成的 Y 染色体浓度达标概率预测曲线，体现了模型捕捉到的个体间差异。

8.4 模型求解与最优方案确定

模型的求解采用 K 均值聚类与网格搜索结合的双层优化算法。外层循环遍历分组数 K 从 2 至 8。对每个 K 值，先对所有样本的 BMI 进行 K 均值聚类以完成分组。随后




图 17 混合效应模型预测的个体 Y 染色体浓度达标概率变化轨迹

在内层优化中，对每个组别，在 70 天至 196 天的时间范围内进行网格搜索，逐日计算其总期望风险，取风险最低点对应的时间作为该组的最佳 NIPT 时点。最后，比较不同 K 值下的加权平均总风险，风险最低者对应的 K 值即为最优分组数。




图 18 不同分组数 K 对应的加权平均总风险

选择最优分组数的过程如图 18 所示。图中以柱状图形式展示了不同分组数 K 对应的加权平均总风险值。计算结果表明，当分组数 K 等于 7 时，加权平均总风险达到所有候选方案中的最小值 4.0656。因此，将孕妇群体划分为七个组别是当前模型下的最优策略。




图 19 最优分组数 K 等于 7 时基于 BMI 的聚类结果

在确定最优分组数为 7 后，对孕妇 BMI 进行聚类的结果可见于图 19。该图以散点形式展示了每一个样本，并用不同颜色标识其所属的群组。七个群组沿孕妇 BMI 轴向分布，形成了七个相互邻接的区间，体现了对孕妇群体的细分。




图 20 最优分组方案下各群组的期望风险曲线

各群组的最佳检测时点由其总期望风险曲线确定，如图 20 所示。图中每条曲线代表一个 BMI 群组的总期望风险随检测孕周的变化。所有曲线初期均呈现下降趋势，之后转为上升。曲线的最低点即为该群组风险最小化的最佳检测时点。一个主要趋势是，

随着孕妇 BMI 的升高，风险曲线的最低点向更晚的孕周移动。

表 6 最优分组方案与 NIPT 时点建议

群组	BMI 范围	孕妇数量	最佳时点 (周)
群组 1	[20.70, 20.70]	4	10.0
群组 2	[26.62, 29.90]	197	12.86
群组 3	[29.93, 31.84]	300	13.29
群组 4	[31.88, 33.98]	260	12.29
群组 5	[34.01, 36.70]	163	15.71
群组 6	[36.79, 41.13]	64	22.43
群组 7	[41.52, 46.88]	10	16.43

最终的分组方案与各组别的最佳 NIPT 时点建议在表 6 中进行了总结。该表明确了每个群组的 BMI 取值范围与孕妇数量。核心结果体现在最佳时点列，数据显示出 BMI 与最佳时点的正向关联。BMI 最低的群组 1，其最佳检测时点为孕 10 周。BMI 较高的群组 6，其最佳检测时点则推迟至孕 22.43 周。此结果为不同 BMI 的孕妇群体提供了差异化的 NIPT 检测时间窗口。

8.5 模型稳定性分析

为检验决策模型所得结论的稳定性，需要评估关键参数与技术标准变动对最优 NIPT 时点选择的影响。本节分别分析了机会成本函数中的时间延迟参数以及 Y 染色体浓度检测阈值这两个核心要素。

8.5.1 机会成本参数敏感性分析

在风险量化模型中，机会成本的计算涉及一个关键参数 Δt ，它代表因检测失败而必须推迟下一次检测的时间间隔。该参数的取值会直接影响失败风险的量化大小，进而改变总风险曲线的形态。为了探究模型对该参数的敏感程度，我们设定其他条件不变，调整了 Δt 的数值。

具体操作中，我们将 Δt 的取值范围设定在 14 天至 28 天之间，并在此区间内进行遍历。对于每一个 Δt 的取值，我们都重新计算所有分组的总期望风险曲线，并求解出新的最优 NIPT 检测时点。这一过程能够展示最优时点如何随失败代价的变化而做出调整。

分析结果如图 21 所示。图中显示，随着时间延迟参数 Δt 的增加，多数群组的最佳检测时点均向更早的孕周移动。时间延迟 Δt 的增加意味着检测失败将导致更高的机会

成本。面对增大的失败代价，决策模型会选择一个更早的检测时间点，此时 Y 染色体浓度达标的预期概率更高，从而降低发生失败的可能性。




图 21 机会成本时间延迟 Δt 的敏感性分析




图 22 Y 染色体浓度阈值对最佳检测时点的影响分析

8.5.2 检测标准变动影响分析

NIPT 检测的成功与否取决于 Y 染色体浓度是否达到临床标准，即 4% 的阈值。这一技术标准可能因检测技术的发展或不同检测机构的实践而发生变动。因此，有必要分析最优时点策略对此类标准变化的依赖性。

为评估这种影响，我们对 Y 染色体浓度阈值进行了调整分析。我们将浓度阈值在 3.5% 至 4.5% 的区间内进行变动，以模拟不同的技术要求或系统性检测偏差。在每个设定的阈值水平下，我们都更新了失败概率的计算函数，并重新运行完整的时点优化流程，为每一个孕妇分组确定新的最佳检测时点。

图 22 展示了各分组的最佳检测时点随浓度阈值变化的趋势。结果表明，当成功检测的标准变得更为严格，即浓度阈值提高时，所有分组的最佳检测时点均一致地向后推迟。这是因为模型需要通过延长等待时间来确保胎儿的 Y 染色体浓度有更大概率生长至新的、更高的标准之上。此结果表明，模型给出的时点建议会根据检测标准的严格程度做出合理的适应性调整。

九、问题三：多因素约束下的 NIPT 时点优化决策

问题三的目标是综合孕妇的身高、体重、年龄与身体质量指数 BMI 等多种因素，在满足特定 Y 染色体浓度达标比例的前提下，为通过 BMI 划分的不同孕妇群体制定风险最小化的最优 NIPT 检测时点。为达成此目标，本文构建了一个职责分离的建模框架。该框架首先利用全体样本数据进行客观的孕妇分群，随后在提纯后的高质量数据子集上训练一个包含多因素的稳健预测模型，最终将分群与预测结果结合，通过带约束的多目标优化方法求解各群组的最优检测策略。具体流程如图所示。

9.1 基于全体样本的孕妇分群

本阶段的目标是在覆盖全部样本的基础上，依据核心指标 BMI 对孕妇进行分组。本文选用 K 均值聚类算法，以孕妇 BMI 为单一聚类维度，对包含 998 条记录的完整数据集进行划分，确保每位孕妇都被纳入分组考量。

最优分组数量 K 的选择，采用了以最终优化目标为导向的决策方法。具体而言，本文遍历不同的分组数 K 从 2 至 8，对每一种分组方案均执行完整的优化流程，并计算在该方案下，全体孕妇在期望达标比例约束为 0.95 时的加权平均总风险。选择使该全局风险最小的 K 值作为最优解。加权平均总风险的计算公式为

$$E[R_{total}]_K = \sum_{i=1}^K \frac{n_i}{N} \cdot R_i^* (\epsilon = 0.95) \quad (29)$$

其中， $E[R_{total}]_K$ 是在 K 个分组方案下的加权平均总风险， n_i 是第 i 组的孕妇人数，N 是总人数， R_i^* 是第 i 组在给定约束下的最小期望风险。




图 23 基于总风险最小化的最优分组数决策




图 24 最优分组数 K 等于 4 时的 BMI 聚类结果

不同 K 值对应的加权平均总风险计算结果展示于图 23。图中横坐标为聚类数量 K，纵坐标为加权平均总风险。曲线显示，当分组数 K 等于 4 时，总风险达到所有候选方案中的最低点 2.753。因此，本文最终确定 K 等于 4 为最优分组数。

依据最优分组数 4，K 均值聚类算法在全体样本上的划分结果如图 24 所示。该图直观展示了四个沿 BMI 值分布的孕妇群组，各组别特征鲜明且相互邻接，最终确定的四个群组及其 BMI 范围分别为：BMI 组 1，范围 20.7 至 31.0；BMI 组 2，范围 31.0 至 33.9；BMI 组 3，范围 33.9 至 37.8；BMI 组 4，范围 38.2 至 46.9。

9.2 多因素非线性关系预测模型

为建立一个能够准确预测 Y 染色体浓度的稳健模型，并避免离群点对模型参数估计的干扰，本阶段首先进行了数据提纯。从完整的 998 条记录出发，对孕周、身高、体

重、年龄、孕妇 BMI 与 Y 染色体浓度六个核心变量，逐一应用 1.5 倍四分位距准则进行离群点检测。该过程最终形成了一个包含 931 条高质量观测记录的干净数据集，专门用于后续预测模型的训练。

模型类型上，本文选择构建非线性混合效应模型，以同时捕捉变量间的复杂非线性关系以及孕妇间的个体差异。根据在干净数据集上的拟合结果，最终确立的预测模型表达式为

$$\begin{aligned}\hat{Y}_{ij} = & u_{0,i} - 7.1472 \\ & + 4.5615 \times 10^{-3} \cdot \text{孕天数}_{ij} - 3.4421 \times 10^{-5} \cdot \text{孕天数}_{ij}^2 + 9.5710 \times 10^{-8} \cdot \text{孕天数}_{ij}^3 \\ & + 0.1274 \cdot \text{BMI}_{ij} - 9.7171 \times 10^{-4} \cdot \text{BMI}_{ij}^2 \\ & + 5.9349 \times 10^{-3} \cdot \text{年龄}_{ij} - 8.5600 \times 10^{-5} \cdot \text{年龄}_{ij}^2 \\ & - 0.0449 \cdot \text{体重}_{ij} + 1.1372 \times 10^{-4} \cdot \text{体重}_{ij}^2 \\ & + 0.0581 \cdot \text{身高}_{ij} - 9.8937 \times 10^{-5} \cdot \text{身高}_{ij}^2 \\ & + 9.1773 \times 10^{-6} \cdot (\text{孕天数}_{ij} \times \text{孕妇 BMI}_{ij}) \\ & - 1.6636 \times 10^{-5} \cdot (\text{孕天数}_{ij} \times \text{年龄}_{ij})\end{aligned}\quad (30)$$

其中， $u_{0,i}$ 是第 i 位孕妇的随机效应截距，代表了个体特异性，其服从均值为 0，方差为 6.965×10^{-4} 的正态分布。

9.3 带约束的时点优化求解

本阶段将前述的分组结果与预测模型进行整合，以求解各组的最优检测时点。本文采用 ε 约束法进行多目标优化。其数学模型的目标函数为最小化总期望风险 $R_{total}(t_g)$ ，同时满足群体期望达标比例 $P_{rate}(t_g)$ 不低于预设阈值 ε 的约束条件。

模型中的关键指标推导如下。首先，基于非线性混合效应模型的预测值 $\hat{Y}_i(t)$ 与残差标准差 $\hat{\sigma}_{residual}$ ，可计算任一孕妇在时间点 t 的个体达标概率

$$P_{pass,i}(t) = 1 - \Phi\left(\frac{0.04 - \hat{Y}_i(t)}{\hat{\sigma}_{residual}}\right)\quad (31)$$

随后，一个群组 g 的群体期望达标比例，定义为该组内所有个体达标概率的算术平均值

$$P_{rate}(t_g) = \frac{1}{|I_g|} \sum_{i \in \text{group}_g} P_{pass,i}(t)\quad (32)$$

总期望风险 $R_{total}(t)$ 则沿用问题二中构建的综合风险函数，它由延迟检测的健康风险

$R_{late}(t)$ 与检测失败的机会成本风险 $R_{fail}(t)$ 两部分构成

$$R_{total}(t) = R_{late}(t) + R_{fail}(t) \quad (33)$$




图 25 期望风险构成与最优时点决策机制

求解过程采用网格搜索算法，在 70 天至 196 天的时间范围内，为每个群组在多个约束水平 ε 下寻找最优时点。图 25 展示了期望风险的构成，以 BMI 组 2 为例，图中总期望风险曲线是健康风险曲线与机会成本风险曲线的叠加。随着孕周增加，健康风险单调递增，而机会成本风险单调递减。两条曲线的权衡使得总风险曲线上存在一个最小值点，该点对应的的时间即为最优检测时点，如图中虚线所示的第 85 天。

9.4 最优策略分析与稳健性检验

综合上述流程，本文得到针对不同 BMI 群组，在不同期望达标比例约束下的最优 NIPT 时点策略矩阵。

图 26 中的热力图是本问题的核心结论，它给出了四个 BMI 组在五种不同期望达标比例要求下的最佳 NIPT 时点。该矩阵揭示了两条明确的规律。其一，孕妇 BMI 越高，推荐的检测时间越晚。在任意期望达标比例约束下，BMI 组别越高，热力图颜色越深，对应的推荐时点越晚。其二，期望达标比例要求越高，推荐的检测时间也越晚。对于任何一个 BMI 组，随着约束值 ε 从 0.85 提高到 0.95，推荐时点均相应推迟。

表 7 与表 8 以表格形式提供了策略矩阵的详细数值，分别以周和天的单位呈现。例如，在 95% 的期望达标比例要求下，BMI 最低的组 1，其最佳时点为孕 11 周加 6 天，即第 83 天；而 BMI 最高的组 4，则需等到孕 24 周加 1 天，即第 169 天。

为检验模型结论在面对现实检测误差时的稳健性，本文进行了敏感性分析。通过蒙特卡洛模拟，在非线性混合效应模型的预测值上，叠加一个服从均值为 0，标准差为




图 26 最优 NIPT 时点策略矩阵




图 27 最优时点对检测误差的敏感性分析

表 7 最优 NIPT 时点策略矩阵 (单位：周 + 天)

	Epsilon=0.85	Epsilon=0.875	Epsilon=0.9	Epsilon=0.925	Epsilon=0.95
BMI 组 1 (20.7-31.0)	11w+5d	11w+5d	11w+5d	11w+5d	11w+6d
BMI 组 2 (31.0-33.9)	12w+1d	12w+1d	12w+1d	12w+1d	12w+3d
BMI 组 3 (33.9-37.8)	13w+1d	13w+1d	13w+1d	13w+2d	14w+4d
BMI 组 4 (38.2-46.9)	22w+6d	22w+6d	22w+6d	23w+2d	24w+1d

表 8 最优 NIPT 时点策略矩阵 (单位：天)

	Epsilon=0.85	Epsilon=0.875	Epsilon=0.9	Epsilon=0.925	Epsilon=0.95
BMI 组 1 (20.7-31.0)	82	82	82	82	83
BMI 组 2 (31.0-33.9)	85	85	85	85	87
BMI 组 3 (33.9-37.8)	92	92	92	93	102
BMI 组 4 (38.2-46.9)	160	160	160	163	169

σ_{error} 的正态分布随机误差。

图 27 中的箱线图展示了 BMI 最高的组 4，在期望达标比例为 92.5% 的约束下，随着检测误差标准差 σ_{error} 从 0.0 增大到 0.015，最优时点分布的变化。结果显示，随着检测误差的增大，推荐的最优时点均值保持稳定，但分布的离散程度显著增加。这表明本决策框架具有良好的稳健性，即使存在一定的检测误差，推荐的最佳时点均值也不会发生剧烈偏移，保证了决策建议的可靠性。

十、问题四：女胎异常判定模型的建立

为对女胎染色体异常情况进行判定，本文建立并评估了多种机器学习模型。数据集中正常与异常样本比例约为 9 比 1，属于类别不平衡问题。研究的核心在于提升模型对少数异常样本的识别能力，即召回率，以满足临床筛查的应用需求。本章阐述了数据

准备，模型训练，性能评估与模型解释的完整过程。

10.1 模型准备与评估方法

10.1.1 数据划分与不平衡处理

为建立公平的训练与评估环境，我们首先将所有经过预处理的女胎数据，依据 7 比 3 的比例执行分层抽样，分别划分为训练集与测试集。分层操作确保了两个数据子集中的异常样本比例与原始数据集保持一致。

为应对数据类别不平衡的问题，我们仅对训练集应用了合成少数类过采样技术 SMOTE。该技术通过在少数类样本附近合成新的样本实例来增加其数量。我们将训练数据中异常样本与正常样本的比例由约 1 比 9 提升至 1 比 2。这种采样比例的目的是在增强模型对少数类别学习能力的同时，避免因引入过多人工样本而可能出现的过拟合现象。测试集则维持其原始数据分布。

10.1.2 候选模型介绍

为完成对女胎染色体异常的判定，本文选取了三种不同的分类算法进行训练与比较。这些算法分别是逻辑回归、决策树与 XGBoost，它们在模型结构和学习方式上各有特点，能够从不同层面分析数据。

逻辑回归是一种用于处理二元分类问题的统计方法。该模型通过一个特定的函数，即逻辑斯谛函数，将自变量的线性组合映射到 0 至 1 的区间内，所得到的数值可以被解释为某个事件发生的概率。对于给定的输入特征向量 X ，其属于正类的概率 $p(X)$ 的计算方式为

$$p(X) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^n \beta_i X_i)}} \quad (34)$$

在此式中， β_0 是截距项， β_i 是第 i 个特征 X_i 对应的模型系数。这些系数是通过训练数据的学习过程估计得出的，通常采用最大似然估计法进行求解。当模型输出的概率值大于预设的阈值，一般为 0.5 时，样本被判定为正类，反之则为负类。

决策树是一种基于树状结构进行决策的非参数学习算法。该模型通过从数据中学习一系列分层的是非问题来对样本进行分类。整个模型的结构形似一棵倒置的树，其中每个内部节点代表对一个特征属性的测试，从该节点引出的每个分支代表测试的一个可能结果，而每个叶节点则代表一个最终的类别标签。决策树的生成是一个递归过程，在每一步，算法会选择一个最优的特征来划分数据集，划分的准则通常是使得划分后数据的纯度最高，例如使用信息增益或基尼不纯度作为度量。这个划分过程会持续进行，直到子集中的所有样本都属于同一类别，或者达到其他预设的停止条件。

XGBoost 是梯度提升框架下的一种算法实现。它属于集成学习方法，通过迭代式地生成一系列弱学习器，通常是决策树，并将它们组合起来形成一个表现更好的学习模型。

该算法以序列化的方式构建模型，在每一轮迭代中，一个新的决策树被训练出来，其目标是修正前面所有树组成的集成模型所犯的误差。具体而言，新的树拟合的是损失函数关于前一轮模型预测结果的负梯度，即残差。第 t 轮迭代后，对样本 x_i 的预测值 $\hat{y}_i^{(t)}$ 由前一轮的预测值与当前轮新加入的树模型 $f_t(x_i)$ 共同构成

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i) \quad (35)$$

最终的预测结果是所有轮次生成的树模型输出值的总和。该方法在损失函数中加入了正则化项，用以控制模型的复杂度，从而防止过拟合。

10.1.3 模型优化与评估指标

为使各模型达到其最优状态，本文采用网格搜索与交叉验证相结合的方法进行超参数调优。网格搜索能够系统性地遍历预先设定的参数组合，从而避免了人工试错的随意性。与交叉验证方法结合使用，可以在不同数据子集上反复评估每一种参数组合的性能，其结果能够比单次划分训练集和验证集提供更稳健的模型泛化能力度量，减少了因特定数据划分而引起的偶然性。

具体实施 5 折分层交叉验证，其优势在于分层抽样保证了每一个折叠中的类别比例都与原始训练集保持一致。在处理类别数量不均衡的数据时，此种方法可确保少数类的样本在每次训练和验证中都得到体现，从而获得更可靠的性能估计。将此过程应用于经过 SMOTE 技术处理后的训练数据，其目的是在不影响测试集真实分布的前提下，缓解模型训练时对多数类的偏向。

将网格搜索的优化评分指标设定为召回率，是直接响应本任务的应用需求。在异常检测的场景下，漏掉一个异常样本的代价远高于将正常样本误判。召回率这一指标直接衡量模型找出所有真实异常样本的能力。因此，以召回率为优化目标，能够使超参数的选择过程导向于构建一个尽可能减少漏诊的模型，使模型的功能与实际应用目标保持一致。

10.2 模型性能比较分析

在模型调优完成后，我们在原始的、未曾见过的测试集上，通过多维度指标对三个模型进行评估，并以此为依据选择最终模型。评估的首要指标是异常类别的召回率，该指标直接度量模型避免漏诊的能力。当召回率相近时，则依次比较 F1 分数、AUC 值以及精确率。

图 28 展示了三个模型在不同阈值设定下区分正常与异常样本的整体能力。图中曲线越靠近左上角，其下方的面积即 AUC 值越大，说明模型的诊断价值越高。逻辑回归模型的 ROC 曲线，其 AUC 值为 0.805，优于决策树的 0.671 和 XGBoost 的 0.692。逻辑




图 28 模型 ROC 曲线对比

回归的曲线包裹了更大的面积，表明其在所有阈值下的判别能力相对更优。



图 29 模型混淆矩阵对比

图 29展示了各模型在测试集上的具体预测分布。测试集中共包含 19 例真实的异常样本。逻辑回归与决策树均成功识别出其中的 9 例，对应 10 例漏诊，两者的召回率均为 47.4 百分比。XGBoost 模型仅识别出 5 例，漏诊 14 例。在误诊方面，逻辑回归将 13 例正常样本错误判断为异常，而决策树的误诊数量为 28 例。此结果表明，在查全能力相同的情况下，逻辑回归的查准能力更优。

表 9对各模型针对异常样本的各项性能指标进行了量化总结。根据此表，逻辑回归与决策树在首要指标召回率上均达到 0.474，并列最高。为作出最终选择，需要比较次要指标。逻辑回归的 F1 分数为 0.439，高于决策树的 0.316，这表明逻辑回归在精确率与召回率之间取得了更好的平衡。同时，逻辑回归的精确率为 0.409，同样高于决策树

表 9 各候选模型在测试集上的性能指标对比

模型	精确率	召回率	F1 分数	AUC
LogisticRegression	0.409	0.474	0.439	0.805
DecisionTree	0.237	0.474	0.316	0.671
XGBoost	0.385	0.263	0.313	0.692

的 0.237，并且其 AUC 值 0.805 也是三者中最高的。因此，基于各项关键评估维度的数值，逻辑回归模型被选定为最终的判定模型。

10.3 最优模型解释性分析

为解释逻辑回归模型判定女胎异常的具体依据，本文采用 SHAP 方法进行模型解释。SHAP 的全称为 SHapley Additive exPlanations，该方法建立在合作博弈论中的夏普利值理论之上，为机器学习模型的预测结果提供解释。其核心思想是将数据样本的每一个特征视为参与一场合作的成员，而最终回报即为模型的预测输出。对于单个预测样本，SHAP 值能够计算出每个特征在所有可能的特征组合中对预测结果的平均边际贡献，从而将模型的预测值公平地分配给各个特征。一个可解释的模型 $g(z')$ 可以用所有特征的 SHAP 值 ϕ_j 线性相加来表示

$$g(z') = \phi_0 + \sum_{j=1}^M \phi_j z'_j \quad (36)$$

在此式中， ϕ_0 代表了数据集中所有样本预测值的平均，也称为基准值。 ϕ_j 即为第 j 个特征的 SHAP 值，它量化了该特征将模型预测结果从基准值推向最终预测值的贡献大小和方向。正值的 SHAP 值表示该特征促使模型预测结果向正类别移动，负值则代表其作用相反。

图 30 与图 31 从不同角度展示了模型的决策机制。图 30 呈现了逻辑回归模型为各特征学习到的系数。横轴代表系数的大小，其正负号与数值决定了特征对判定结果为异常概率的影响方向和强度。图中显示，13 号染色体的 GC 含量与唯一比对的读段数具有最大的正向系数，约等于 4，表明这些指标数值的增加会使模型判定为异常的可能性显著上升。孕周与孕妇 BMI 等特征也表现出正向影响。与此相反，原始读段数和 21 号染色体的 GC 含量具有较大的负向系数，接近负 4，说明这些指标数值的增加会使模型判定为异常的可能性下降。

图 31 则通过 SHAP 值为模型的决策提供了更细致的个体化解释。图中每一行代表一个特征，按其对模型输出的平均影响大小排序。横轴为 SHAP 值，每个点代表一个测试样本。点的颜色表示该样本对应特征值的相对高低，红色为高，蓝色为低。该图表明，唯一比对的读段数是对模型预测影响最大的特征，其特征值较高时，SHAP 值普遍为正，




图 30 逻辑回归模型特征重要性排序




图 31 SHAP 摘要图

增加了判定为异常的概率。原始读段数的影响力次之，其特征值较低时，SHAP 值倾向于为正。对于临床上关注的指标，例如 21 号染色体的 Z 值，图中显示其数值越高，颜色越红，对应的 SHAP 值也越大，更倾向于将胎儿判定为异常。这一规律与临床诊断 21 三体综合征的原理相符。

该解释性分析证实，模型的判定主要依据各项染色体 Z 值、读段数以及 GC 含量等临床与测序关键指标，其决策逻辑与医学先验知识高度一致，从而验证了模型的有效性与可靠性。

参考文献

- [1] 张亮亮, 卓召振, 黄盛文, 任凌雁, 牟静, and 匡颖. 贵州省多中心 16798 例 nipt-plus 结果回顾性分析. 贵州医药, 49(08):1296–1299, 2025.
- [2] 张鹏, 莫伟英, 蒙明慧, and 张红燕. 无创产前检测对性染色体非整倍体检出情况的影响及相关伦理思考. 中国临床新医学, 18(06):690–695, 2025.
- [3] 钟佳通, 胡亮, 温丽娟, 李双武, 陈晓杭, 裴元元, and 刘维强. 双胎妊娠中无创产前检测的胎儿游离 dna 浓度特征及检测失败原因分析. 中国产前诊断杂志 (电子版), 15(03):25–30, 2023.
- [4] 蒋丽雅, 卢劭侃, 杜佳恩, 陈阔阔, 张思恬, 伍圣洁, 柳天玉, and 叶佳昊. 无创产前检测技术的发展与应用. 临床医学研究与实践, 10(23):191–194, 2025.