

基于机器学习与关联网络的古代玻璃成分分析

摘要

古代玻璃的化学成分是鉴别其类别与产地的重要依据，然而风化作用会改变原始成分，为定量分析带来挑战。本文基于一批古代玻璃制品的化学成分数据，建立了一套多层次的数学模型，以解决风化影响下的玻璃分类、成分预测与内在关联分析问题。研究综合运用了统计检验、机器学习、智能优化算法与复杂网络理论，为通过化学成分数据理解古代玻璃制品提供了系统性的分析方案。

对于问题一，我们采用**卡方检验**分析了表面风化与玻璃类型、纹饰及颜色的关联性，确认了它们之间存在统计学关联。通过对比风化前后样本的化学成分分布，发现风化主要导致高钾玻璃中的氧化钾与铅钡玻璃中的氧化铅和氧化钡流失。为预测风化前的成分，本文引入**地球化学领域的质量平衡分析理论**，构建了基于风化系数的预测模型，该模型在缺乏成对样本的情况下，能够有效恢复文物的原始化学成分。

对于问题二，为研究两大类玻璃的分类规律，我们分别构建了**线性与非线性支持向量机模型**。其中，非线性模型获得了 97.41% 的交叉验证准确率，我们引入**博弈论中的 SHAP 值**对其进行解释，而线性模型的结果则直接验证了氧化铅与氧化钾是分类的核心指标。在亚类划分中，我们依据**变异系数**筛选特征，并结合**层次聚类与轮廓系数**，确定铅钡玻璃存在两个亚类，高钾玻璃存在五个亚类。划分结果显示铅钡玻璃可分为高铅钡助熔剂型与高硅基质型，高钾玻璃的亚类则在多种成分上表现出不同特征。

对于问题三，我们构建了基于**改进遗传算法优化的支持向量机分类器 IGA-SVM**，以鉴别未知类别文物的所属类型。该模型通过智能化全局寻优确定最优超参数组合，避免了传统模型选择的局限性。应用此模型，我们完成了对全部未知样本的分类。为确保结果的可靠性，我们设计了基于**蒙特卡洛模拟**的数据扰动与基于**参数网格搜索**的模型扰动双重灵敏度分析，验证了分类结果对于数据测量误差和模型参数选择的高度稳健性。

对于问题四，为探寻不同类别玻璃配方的内在结构差异，我们构建了**化学成分关联网络**。为消除成分数据总和恒定带来的虚假相关，我们首先采用化学计量学中的**中心化对数比变换**对数据进行处理。随后利用**图套索算法**计算偏相关系数以构建网络，并应用**鲁汶算法**进行社群发现。网络分析结果表明，铅钡玻璃与高钾玻璃的化学成分关联结构存在显著不同，前者以二氧化硅和氧化铅为核心形成紧密社群，后者则结构较为分散，这些差异反映了两者在原料与烧制工艺上的区别。网络分析结果表明，铅钡玻璃与高钾玻璃的化学成分关联结构存在显著不同，前者以二氧化硅和氧化铅为核心形成紧密社群，后者则结构较为分散，这些差异反映了两者在原料与烧制工艺上的区别。

关键字：卡方检验 地球化学 质量平衡分析理论 SHAP 值 支持向量机 中心化对数比 图套索算法 鲁汶算法

一、问题背景

NIPT（无创产前检测）是一种现代产前筛查技术，它通过分析孕妇外周血中来自胎儿的游离 DNA 片段，评估胎儿患有染色体非整倍体疾病的风险^[1]。临床上重点关注三类由染色体数目异常引起的病症，分别为唐氏综合征、爱德华氏综合征与帕陶氏综合征，它们分别对应胎儿 21 号、18 号与 13 号染色体的异常^[2]。该检测的有效性依赖于胎儿性染色体浓度：男胎 Y 染色体浓度需达 4%^[3]，女胎 X 染色体浓度则需无异常。

检测时点的选择是影响检测有效性的一个重要变量。若检测时间过早，胎儿游离 DNA 浓度可能不足，这将导致检测结果无法保证准确性。反之，若检测时间过晚，则可能会延误后续的临床决策。根据临床经验，孕 12 周以内发现异常属于低风险，孕 13 至 27 周发现属于高风险^[4]，而孕 28 周以后发现则为极高风险。

临床实践常依据身体质量指数 BMI 对孕妇分组并推荐统一检测时点，但该方法因忽略年龄、孕情等个体差异，并非最优。因此，需建立数学模型对孕妇进行合理划分，确定各群体的最佳检测时点，以平衡检测可靠性并降低延迟发现的风险。




图 1 问题背景示意图

二、问题重述

问题一：分析胎儿染色体浓度与孕妇孕周数和身体质量指数等指标的相互关系，并建立相应的关系模型。

问题二：针对男胎孕妇，依据其身体质量指数进行分组，确定各组的最佳无创产前检测时点以使潜在风险最小，并分析检测误差造成的影响。

问题三：考虑身高，体重，年龄等多重因素与检测误差，根据男胎孕妇的身体质量指数进行分组，并给出每组的最佳无创产前检测时点，以最小化孕妇潜在风险并顾及 Y 染色体浓度达标比例。

问题四：建立女胎染色体异常的判定方法，运用 Z 值，GC 含量，读段数及身体质量指数等多种因素，以识别 21 号，18 号和 13 号染色体的非整倍体异常。

三、问题分析（需修改）

针对问题一，该问题涉及两个层面，其一是定性关系的判断，其二是定量规律的分析与预测。表面风化与玻璃类型、纹饰、颜色均为分类变量，它们之间的关联性分析适合采用非参数的卡方检验。风化对化学成分含量的影响则需要分组进行统计比较，通过观察含量分布的变化来识别规律。由于缺乏同一文物风化前后的成对数据，直接建立回归预测模型存在困难，因此分析的重点在于依据风化机理，构建一个基于平均变化率的风化系数模型，用以反推风化前的化学成分。

针对问题二，该问题需要从监督学习与无监督学习两个角度展开。高钾与铅钡玻璃的分类规律研究是一个典型的二分类问题，可以基于探索性数据分析发现的关键化学成分，构建支持向量机等分类模型，并对模型进行解释。

针对问题三，该问题是分类模型的实际应用与可靠性验证。分析的核心在于构建一个泛化能力强且稳健的分类器。这需要比较多种模型架构，并论证选择支持向量机的合理性。为使模型性能最优化，需要采用改进遗传算法等智能优化算法进行超参数寻优。最终的鉴别结果需要通过数据扰动和模型参数敏感性分析的双重检验，以证明其结论并非偶然，而是具有高度的可靠性。

针对问题四，该问题要求探寻不同类别玻璃内部化学成分的关联结构。由于玻璃成分数据具有总和恒定的特性，直接计算相关系数会产生误导，因此必须首先采用中心化对数比变换来消除此统计约束。直接计算相关系数会产生误导，因此必须首先采用中心化对数比变换来消除此统计约束。

全文框架如图 2 所示：



图 2 全文框架示意图

四、模型假设（需修改）

为保证模型构建的合理性与分析过程的严谨性，我们提出以下基本假设。

1. 所有用于分析的数据均为成分总和在百分之八十五至一百零五区间的有效数据。
2. 数据中的空白项表示该化学成分未被检测到其含量可视为零。
3. 同一类型玻璃的风化过程与化学成分变化规律具有统计上的一致性。
4. 文物的化学成分组合能够有效地区分高钾玻璃与铅钡玻璃两大类别。
5. 同一文物多个采样点的平均化学成分可以代表该文物的整体特征用于亚类划分。
6. 化学成分间的偏相关关系能够反映其在玻璃配方或制作工艺中的直接关联。

五、符号说明（需修改）

本文后续章节中所使用的主要数学符号及其说明如表所示。

表 1 符号说明表

符号	说明
$k_{t,j}$	t 类玻璃中 j 成分的风化系数
$\bar{C}_{t,j,\text{weathered}}$	t 类玻璃风化样本中 j 成分的平均含量
$\bar{C}_{t,j,\text{unweathered}}$	t 类玻璃未风化样本中 j 成分的平均含量
$C'_{\text{unweathered},j}$	某一样本风化前 j 成分的预测含量
$\mathbf{w}, b$	支持向量机分类超平面的法向量与位移项
C	支持向量机的正则化系数
γ	径向基核函数的参数
ξ_i	支持向量机的松弛变量
CV	变异系数，用于衡量数据的相对离散程度
$\text{clr}(\mathbf{x})$	对样本向量 $\mathbf{x}$ 进行中心化对数比变换
S	样本协方差矩阵
Θ	精度矩阵，即逆协方差矩阵
λ	图套索算法的正则化参数
$\rho_{ij\cdot\text{rest}}$	变量 i 和 j 之间的偏相关系数

六、模型准备

为了后续模型的建立与求解，本文进行如下模型准备，即数据清洗、数据量化等。具体机制如图 3 所示。



图 3 模型准备机制

6.1 数据清洗

6.1.1 缺失值处理与数据整合

为简化数据集，我们移除了与建模任务无直接关联的序列列。随后，我们对数据集中各变量进行缺失值统计，发现末次月经时间列存在部分数据缺失。末次月经时间的主要功能为推算孕周，而数据集中已包含更为直接的检测孕周列，故将其移除。

为使原始特征能够用于定量分析，我们需要将其转化为标准的数值格式。对于纯数字格式的检测时间列，我们将其转换为标准的日期时间格式；对于文本格式的检测孕周列，我们转换为可计算的浮点数值，例如十二周加三天转化为 12.43 周。对于孕妇 BMI 指标列中的缺失值，我们利用同一条记录的身高与体重数据，依据身体质量指数的官方计算公式进行填充，该公式如下所示

$$BMI = \frac{Weight(kg)}{Height(m)^2} \quad (1)$$

与使用均值或中位数等统计量填充相比，利用已有数据进行计算能最大限度地保持数据的真实性。

完成基础清洗与计算后，数据集内核心特征的整体分布如图 4 所示。该图展示了孕妇年龄，孕妇 BMI 与检测孕周三个变量的分布状况。从图中可以看出样本的年龄主要集中在 25 至 35 岁之间，孕妇 BMI 分布的峰值位于 30 附近，证实了样本多为高 BMI 的地区特征。检测孕周则在 12 至 25 周之间呈现多个峰值，表明了检测时间点的集中性。




图 4 核心特征分布

题目中提到存在对同一孕妇进行重复检测的情况，这导致了数据冗余。为消除此冗余，我们以孕妇代码与检测抽血次数为唯一标识，对同一抽血样本的多次检测记录进行数据整合。整合时，对于连续性测量指标，取其算术平均值以减小单次测量的随机误差影响；对于分类性状态指标，则保留其首次出现的值。

图 5展示了数据整合前后的样本数量变化。如左图所示，处理前单个孕妇的样本记录数最高可达 9 条，多数孕妇具有 1 至 6 条记录。经过整合处理后，转变为每次抽血对应唯一记录的形式。如右图所示，单个孕妇的有效检测次数减少至 1 至 5 次，大部分孕妇只有 4 次有效检测，从而消除了冗余信息。

根据题目说明，原始数据中存在同一孕妇多次采血多次检测或一次采血多次检测的情况，这种情况造成了数据冗余。为消除此冗余并为每个样本建立唯一的检测记录，本文以孕妇代码与检测抽血次数的组合为标识，对重复的检测条目进行聚合处理。在聚合过程中，对于连续型测量指标，采用算术平均值以平滑单次测量的随机波动。对于分类性质的状态指标，则保留其初次记录的值。

该聚合过程的效果通过图 5中的前后对比得以展示。左图显示在处理前，单个孕妇对应的所有样本的所有检测记录数从 1 条至 9 条不等，其中多数孕妇具有 3 至 6 条记录。经过聚合处理后，如右图所示，每位孕妇的有效检测次数范围缩小至 1 至 5 次，其中具有 4 次有效检测的孕妇数量最多。




图 5 数据整合效果对比

6.1.2 异常值处理

我们首先针对年龄，孕妇 BMI 与孕周这三个核心特征执行四分位距法检验。对于识别出的离群点，本文采用软标记方法，即在数据集中新增一列用以标记样本是否为离群点，而不直接删除样本记录。离群点可能代表了真实存在的极端生理状况或数据录入错误，采用软标记策略为后续建模提供了灵活性。图 6展示了离群点分析的过程，图中每个子图的小提琴形状表示了数据的分布，红色的圆点则标记出被标准四分位距准则判定为离群点的样本。图中可见，年龄的离群点主要分布在 40 岁以上的高龄区间，孕妇

BMI 的离群点则同时出现在低于 20 的低值区域与高于 40 的高值区域，而孕周的离群点相对较少。




图 6 IQR 离群点分析

其次我们对 GC 含量进行质量控制。GC 含量是衡量测序质量的重要指标。处理过程结合了统计学检验与业务规则，先对 GC 含量列执行标准的 1.5 倍四分位距检验以识别出所有统计学上的离群点。然后，仅将这些离群点中数值低于 40% 的样本从数据集中直接删除。此方法能够剔除那些不仅在统计上异常，且低于业务经验常规下限的低质量测序样本。图 7 展示了处理后的数据，其中直方图展示了 GC 含量的整体分布形态近似正态分布，频数在 0.400 处达到峰值，绝大多数样本的 GC 含量分布在 0.395 至 0.405 之间，分布集中，数据质量较高。




图 7 GC 含量离群点分析

6.2 数据量化

为了便于后续相关数学模型的建立与求解，增强可理解性，我们进一步进行了数据量化。

针对不同问题,我们构建了相应的目标变量。对于男胎数据,依据题目定义的 4% 阈值,我们创建了“Y 浓度是否达标”的二元分类变量。对于女胎数据,则基于染色体的非整倍体列中空白即为无异常的定义,创建了“是否异常”以及各类异常的分类目标。图 8 展示了女胎样本中正常与各类异常样本的数量分布。图中可见正常样本数量为 488 例,而 18 号,13 号与 21 号染色体三体综合征的样本数量分别为 45 例,22 例与 13 例。正常样本远多于异常样本,表明这是一个数据不平衡问题。




图 8 染色体异常类型分布

考虑到问题四需要使用机器学习分类模型,我们仅针对女胎数据的所有数值型预测特征应用了标准化处理。标准化将所有特征转换到同一尺度,其计算方法如下

$$z = \frac{x - \mu}{\sigma} \quad (2)$$

其中 x 为原始值, μ 为特征均值, σ 为特征标准差。此操作避免了模型的训练过程被原始读段数等具有极大数值范围的特征所主导,使模型能够更稳定地学习所有特征的贡献。男胎数据因主要用于回归和优化分析,保留其原始数值的物理意义更为重要,故不进行缩放。??展示了女胎数据中所有数值型预测变量在缩放前后的分布对比。每个子图呈现了同一特征在处理前后的分布形态,处理前各变量的分布中心与尺度范围各不相同,而经过标准化处理后,所有变量的分布均被调整至以 0 为中心,具有相似的尺度,这为后续机器学习模型的训练提供了同质化的输入。

此外,我们还构建了部分衍生特征。我们依据题目对风险的定义,创建了与孕周对




图 9 所有数值特征缩放效果对比

应的风险等级特征。同时, 为进行时序分析, 还计算了每次检测距首次检测的天数。

七、问题一：关系模型的建立与求解

为识别影响男胎 Y 染色体浓度的主要因素并量化其作用，我们先构建最终数据集，再通过探索性分析与迭代建模建立能反映数据规律的关系模型。具体流程见图 10。




图 10 关系模型的建立与求解流程

7.1 数据准备与探索性分析

任何有效的关系模型都建立在高质量的数据基础之上。原始数据中可能存在的极端观测值会对模型参数的估计产生不成比例的影响，进而影响模型的稳定性与泛化能力。为了获得一个稳健的分析数据集，本文首先对因变量即 Y 染色体浓度进行了离群点检验。该过程采用四倍四分位距准则来识别并移除数据中的极端值。处理完成后，最终用于建模的数据集包含 962 条观测记录，这些记录源于 261 位独立的孕妇。




图 11 Y 染色体浓度离群点剔除过程

图11为了 Y 染色体浓度数据的筛选过程。图中通过堆叠直方图对比了保留样本与剔除样本的分布情况，其中的红色虚线标示了依据四分位距准则计算得出的离群点判断上边界。

在构建正式模型之前，需要对变量间的关系形态进行初步探查，为模型形式的选择提供依据。本文通过绘制散点图并叠加局部加权散点平滑曲线来检视 Y 染色体浓度与孕周，Y 染色体浓度与孕妇身体质量指数 BMI 之间的关系。

如图12所示，Y 染色体浓度与孕周的关系通过平滑曲线呈现出 S 型趋势，表明两者之间存在非线性关系。相比之下，图13中 Y 染色体浓度与孕妇 BMI 的散点分布则较为分散。

为对变量间的关联程度进行定量评估，本文计算了两种相关性度量指标及其对应的统计显著性水平。

皮尔逊相关系数 r 用于衡量两个连续变量间线性关系的强度与方向。其取值范围为-1 至 1，绝对值越接近 1 表示线性关系越强。计算公式为

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (3)$$




图 12 Y 染色体浓度与孕周的散点关系




图 13 Y 染色体浓度与 BMI 的散点关系

其中 x_i 与 y_i 是第 i 对观测值， $\bar{x}$ 与 $\bar{y}$ 分别是两个变量的样本均值， n 是样本总数。皮尔逊 P 值用于检验这种线性相关的统计显著性。它通过将相关系数 r 转换为 t 统计量来计算，公式如下

$$t = r \sqrt{\frac{n-2}{1-r^2}} \quad (4)$$

P 值表示在原假设即两个变量无线性关系成立的条件下，获得当前或更极端 t 统计量的概率。

斯皮尔曼相关系数 ρ 则用于度量变量间的单调关系，它不要求变量呈线性关系。该系数同样取值于 -1 至 1 之间。计算时先将原始数据转换为等级，再根据等级计算皮尔逊相关系数，其简化计算公式为

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (5)$$

此处 d_i 是第 i 对观测值的等级之差。斯皮尔曼 P 值同样用于检验单调关系的显著性，其检验统计量的计算方式与皮尔逊 P 值的类似。

表 2 Y 染色体浓度与核心自变量的相关性分析

变量对	皮尔逊相关系数 r	Pearson P 值	斯皮尔曼相关系数 ρ	Spearman P 值
Y 浓度 vs 孕周	0.1087	0.0007	0.0851	0.0083
Y 浓度 vs BMI	-0.1531	0.0000	-0.1321	0.0000

表2展示了相关性计算的结果。所有 P 值均远小于 0.01，说明观测到的相关性在统计上是显著的。然而，相关系数的绝对值均较小，例如 Y 染色体浓度与孕周的皮尔逊相关系数为 0.1087，与 BMI 的相关系数为 -0.1531。这些数值表明变量间的线性关系较弱。此量化结果与散点图的观察相符，进一步说明使用简单的线性模型可能无法充分捕捉变量间的动态关系。

7.2 关系模型的构建与择优

基于探索性分析发现，本文构建了四种不同形式的模型来拟合 Y 染色体浓度与孕周及孕妇 BMI 之间的关系，并通过一系列统计指标对它们的性能进行比较，以选取最合适的模型。

7.2.1 模型构建

模型一为多元线性回归模型，作为后续比较的基准。其形式为

$$Y_{ij} = \beta_0 + \beta_1 GW_{ij} + \beta_2 BMI_{ij} + e_{ij} \quad (6)$$

模型二为多元多项式回归模型，用以分析之前发现的非线性关系。其形式为

$$Y_{ij} = \beta_0 + \sum_{k=1}^p \beta_k GW_{ij}^k + \sum_{l=1}^q \gamma_l BMI_{ij}^l + e_{ij} \quad (7)$$

模型三为广义线性模型，它通过对数连接函数处理可能的指数关系。其形式为

$$g(E[Y_{ij}]) = \beta_0 + \beta_1 GW_{ij} + \beta_2 BMI_{ij} \quad (8)$$

其中 $g(\cdot)$ 为对数连接函数。

数据中包含同一孕妇的多次检测记录，孕妇个体间的生理差异可能对 Y 染色体浓度有影响。为解释这种个体异质性，本文引入了非线性混合效应模型作为**模型四**。该模型在固定效应的基础上，为每个孕妇个体设置了随机效应。其具体形式为

$$\begin{aligned} Y_{ij} = & \underbrace{(\beta_0 + u_{0i})}_{\text{随机截距}} + \underbrace{\left((\beta_1 + u_{1i}) GW_{ij} + \sum_{k=2}^p \beta_k GW_{ij}^k \right)}_{\text{孕周主效应 (含随机斜率)}} \\ & + \underbrace{\left(\sum_{l=1}^q \gamma_l BMI_{ij}^l \right)}_{\text{BMI 主效应}} + \underbrace{\left(\sum_{k=1}^p \sum_{l=1}^q \delta_{kl} (GW_{ij}^k \cdot BMI_{ij}^l) \right)}_{\text{多指数交互效应}} + e_{ij} \end{aligned} \quad (9)$$

在此模型中， Y_{ij} 表示第 i 位孕妇在第 j 次检测时的 Y 染色体浓度。 GW_{ij} 与 BMI_{ij} 是对应的孕周和身体质量指数。 β_0, β_k 与 γ_l 是固定效应系数，代表了样本总体的平均趋势。 u_{0i} 与 u_{1i} 是随机效应项，分别代表第 i 位孕妇的个体基线水平和对孕周影响的个体差异，它们服从均值为 0 的正态分布。 e_{ij} 是随机误差项。

7.2.2 模型择优

为在不同形式的模型中进行择优，本文包含多个维度的评估准则，分别从模型拟合度，复杂性惩罚，预测误差和变异解释度四个方面对模型进行评价。

对数似然值，记作 LL ，是衡量模型拟合优度的基本指标。它表示在给定模型参数下，观测数据出现的概率的对数。较高的对数似然值说明模型能更好地拟合样本数据。对于一组独立同分布的样本，其计算公式为

$$LL = \sum_{i=1}^n \ln(f(y_i|\theta)) \quad (10)$$

其中 y_i 是第 i 个观测值， $f(y_i|\theta)$ 是模型在参数 θ 下关于 y_i 的概率密度或概率质量函数， n 为样本量。

赤池信息准则 AIC 与贝叶斯信息准则 BIC 是基于信息论的模型选择标准。它们在对数似然值的基础上，对模型的参数数量施加惩罚，从而在拟合优度与模型简洁性之间进行权衡。数值较小的模型被认为是更优的选择。

$$AIC = 2k - 2LL \quad (11)$$

$$BIC = k \ln(n) - 2LL \quad (12)$$

在上述公式中， k 代表模型中待估参数的个数。 BIC 对参数数量的惩罚项 $k \ln(n)$ 比 AIC 的惩罚项 $2k$ 更大，因此 BIC 倾向于选择更为简洁的模型。

均方根误差 $RMSE$ 用于度量模型预测值与真实值之间的偏差大小。它的计算结果与因变量的单位相同，直观反映了模型的平均预测误差。 $RMSE$ 的数值越小，表明模型的预测精度越高。其计算公式为

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

此处 y_i 是真实观测值， $\hat{y}_i$ 是模型对第 i 个样本的预测值。

决定系数 R^2 衡量的是模型对因变量方差的解释比例。其取值通常在 0 到 1 之间，越接近 1 说明自变量对因变量的解释能力越强，模型对数据的拟合程度越好。对于普通线性模型，其定义为

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (14)$$

公式中分子的部分是残差平方和，分母的部分是总平方和， $\bar{y}$ 是观测值的样本均值。

对于混合效应模型，决定系数的概念被进一步划分为边际决定系数与条件决定系数，它们分别量化了模型中固定效应部分以及整个模型对因变量变异的解释程度。

边际决定系数 R^2_{marginal} 表示仅由模型中的固定效应解释的方差比例。它反映了群体平均趋势的解释能力。其计算公式为

$$R^2_{\text{marginal}} = \frac{\sigma_f^2}{\sigma_f^2 + \sigma_r^2 + \sigma_\epsilon^2} \quad (15)$$

在此公式中， σ_f^2 是固定效应预测值的方差， σ_r^2 是随机效应的方差， σ_ϵ^2 是模型残差的方差。

条件决定系数 $R^2_{\text{conditional}}$ 表示由固定效应和随机效应共同解释的方差比例。它反映了考虑个体差异后，整个模型的解释能力。其计算公式为

$$R^2_{\text{conditional}} = \frac{\sigma_f^2 + \sigma_r^2}{\sigma_f^2 + \sigma_r^2 + \sigma_\epsilon^2} \quad (16)$$

该指标在分子中加入了随机效应的方差 σ_r^2 ，因此其值总会大于或等于边际决定系数。这两个指标共同为混合效应模型的性能提供了更全面的评估。

表 3 四种候选模型的评估指标对比

模型	对数似然值	AIC	BIC	RMSE	R ²
M1 线性回归	1999.22	-3992.43	-3977.82	0.0303	0.0377 ^a
M2 多项式回归	1999.61	-3991.23	-3971.75	0.0303	0.0375 ^a
M3 广义线性模型	2005.10	-4004.20	-6420.10	0.0303	-0.0107 ^b
M4 混合效应模型	2379.25	-4740.50	-4696.68	0.0096	边际: 0.4197, 条件: 0.9158

^a 调整后决定系数

^b 伪决定系数

表3的评估结果显示，模型一与模型二的调整后决定系数均低于 0.04，说明仅考虑固定效应的线性和多项式模型对 Y 染色体浓度变异的解释能力有限。模型三的伪决定系数为负值，表明该模型的拟合效果差于基础的均值模型。

相比之下，模型四的各项指标均表现出优势。其对数似然值最高，AIC 与 BIC 值最低，说明该模型在拟合优度与模型复杂度之间取得了更好的平衡。模型四的均方根误差 RMSE 为 0.0096，远低于其他模型。该模型提供了两种决定系数，边际 R^2 为 0.4197，代表仅由固定效应即孕周和 BMI 所解释的变异比例。条件 R^2 为 0.9158，它代表由固定效应和随机效应共同解释的变异比例。这一数值说明，在考虑了孕妇的个体差异后，模型能够解释 Y 染色体浓度超过 91% 的变异。

图14对比了线性模型与非线性混合效应模型的拟合效果。混合效应模型捕捉到的趋势显然更能贴合数据的整体分布形态。综合各项指标，本文最终选择非线性混合效应模型来描述 Y 染色体浓度与母体指标的关系。




图 14 线性模型与非线性混合效应模型拟合效果对比

7.3 最终模型解析与显著性检验

在确定采用非线性混合效应模型后，本文通过似然比检验对其具体形式进行了优化。检验结果表明，在模型中加入孕周的二次项能提升模型拟合度，而更高阶的项或交互项则无显著改善。因此，最终确立的模型形式为

$$\begin{aligned} \hat{Y}_{ij} = & \underbrace{(-0.1135 + u_{0,i})}_{\text{个体基础水平}} + \underbrace{(0.0329 + u_{1,i})}_{\text{个体线性变化率}} \cdot GW_{ij} \\ & - 0.00190 \cdot GW_{ij}^2 + 0.0000389 \cdot GW_{ij}^3 - 3.378 \times 10^{-7} \cdot BMI_{ij}^3 \end{aligned} \quad (17)$$

其中 Y_{ij} 为因变量， GW_{ij} 与 BMI_{ij} 为自变量， β 系列参数为固定效应系数， u 系列参数为随机效应项。为检验模型中各固定效应的统计显著性，本文对模型的参数估计结果进行分析。

模型参数的评估与检验涉及多个关键指标，它们共同为判断变量效应的显著性与模型的有效性提供依据。

首先是估计系数，记作 $\hat{\beta}$ 。它由模型拟合过程即受限最大似然法得到，其数值是通过最大化样本数据在给定模型结构下的似然函数来确定的。此系数代表了自变量每变化一个单位，对因变量产生的平均效应的量化估计。

其次是标准误差，记作 $SE(\hat{\beta})$ 。它是对估计系数 $\hat{\beta}$ 抽样分布标准差的估计，反映了

估计值的精密度。标准误差的数值越小，表明参数估计的确定性越高。其计算源于模型参数的方差协方差矩阵的对角线元素

$$SE(\hat{\beta}_k) = \sqrt{Var(\hat{\beta}_k)} \quad (18)$$

其中 $Var(\hat{\beta}_k)$ 表示第 k 个估计系数 $\hat{\beta}_k$ 的方差。

为进行假设检验，需要计算 z 统计量。该统计量衡量估计系数偏离原假设零值的标准误差倍数，其意义在于将估计系数的差异标准化，以便于进行统计推断。计算公式为

$$z = \frac{\hat{\beta} - \beta_0}{SE(\hat{\beta})} \quad (19)$$

在此公式中， β_0 是原假设下的参数值，通常设为零以检验变量的效应是否显著。

根据 z 统计量可以计算出 P 值。它是在原假设即系数为零成立的前提下，观测到当前或更极端统计量的概率。 P 值越小，表明观测结果越不可能由随机抽样误差造成的，拒绝原假设的理由越充分。对于双侧检验，其计算公式为

$$P = 2 \cdot \Phi(-|z|) \quad (20)$$

其中 Φ 是标准正态分布的累积分布函数， $|z|$ 是 z 统计量的绝对值。

最终模型的固定效应参数估计与检验结果如下表所示。

表 4 最终模型固定效应参数估计与检验

固定效应	估计系数	z 统计量	P 值
截距	-0.1135	-2.479	0.013
孕周	0.0329	4.162	<0.001
孕周二次项	-0.0019	-4.247	<0.001
孕周三次项	3.89e-05	4.772	<0.001
BMI 三次项	-3.38e-07	-1.800	0.072

表4的参数估计结果揭示了各变量对 Y 染色体浓度的具体影响。孕周的线性，二次项与三次项的 P 值均远小于 0.001，表明这些效应在统计上是极端显著的。这些系数共同作用，构成了 Y 染色体浓度随孕周变化的 S 型曲线关系。孕妇 BMI 三次项的 P 值为 0.072，处于统计学上的边缘显著水平，说明其对 Y 染色体浓度的影响相对微弱。

模型的决定系数分解结果为理解变异来源提供了定量证据，见表5。边际 R^2 为 0.4197，这表明由孕周和 BMI 构成的固定效应，即所有孕妇共有的普遍规律，能够解释 Y 染色体浓度总体变异的 41.97%。条件 R^2 的值为 0.9158，这意味着当模型同时考虑普

表 5 最终模型决定系数

指标	值
边际 R^2	0.4197
条件 R^2	0.9158

遍规律和个体差异即随机效应后，其对总体变异的解释能力上升至 91.58%。

两者之差，即 91.58% 减去 41.97% 等于 49.61%，这部分变异由不可观测的孕妇个体特异性所解释。个体差异即随机效应的影响程度 49.61%，超过了所有可观测变量即固定效应的总和 41.97%。这一结果表明，个体差异是 Y 染色体浓度变异的主导因素。模型的方差成分进一步量化了这种差异，其中随机截距的方差为 1.627e-03，随机斜率的方差为 6.682e-06。




图 15 最终模型揭示的总体趋势与个体差异

图15是最终模型结果的可视化呈现，是问题一的核心结论。图中的红色粗线代表了由固定效应决定的总体平均趋势，即所有孕妇共有的 S 型变化规律。大量的蓝色细虚线则代表了考虑随机效应后，每一位孕妇个体的实际拟合轨迹，直观展现了巨大的个体差异。

综合来看，Y 染色体浓度的变化遵循一个由孕周主导的 S 型非线性变化，这一趋势具有统计学意义。然而，该规律在不同孕妇间的表现存在显著的差异性，个体差异性

引起浓度变化的更主要来源。相比之下，孕妇的 BMI 在此模型中仅表现出边缘显著的微弱影响。

八、问题二：分组优化与 NIPT 时点决策模型

问题二要求为不同身体质量指数即 BMI 的男胎孕妇制定分组方案，并为各组确定唯一的最佳 NIPT 检测时点。该策略的目标是最小化全体孕妇的潜在风险总和。决策过程需要在两种风险之间权衡，一是过早检测可能因 Y 染色体浓度不达标而失败，二是过晚检测会缩短临床干预的有效时间。为处理此权衡问题，本文建立了一个包含孕妇分组与时点选择的双层决策模型。具体机制如图 16 所示。



图 16 问题二流程图

8.1 风险量化与优化目标

模型顶层的优化目标为寻找最优的分组数量 K ，使所有组别按其人口比例加权的期望风险总和达到最小。总期望风险 $E[R_{total}]$ 的数学表达式为

$$\min_{K, \{t_i\}} E[R_{total}] = \sum_{i=1}^K \frac{n_i}{N} \cdot R_i^*(t_i^*) \quad (21)$$

其中 N 为孕妇总数， n_i 为第 i 组的人数， $R_i^*(t_i^*)$ 是第 i 组在其最优检测时点 t_i^* 下的最小期望风险。对于任何分组 i ，其在特定检测时点 t_i 的总期望风险 $R_i(t_i)$ 由两部分构成

$$\min_{t_i} R_i(t_i) = R_{late}(t_i) + R_{fail}(t_i) \quad (22)$$

此处的 $R_{late}(t_i)$ 是因推迟检测累积的健康风险， $R_{fail}(t_i)$ 是因检测失败造成的机会成本风险。 $R_{late}(t_i)$ 随时间增加，而 $R_{fail}(t_i)$ 随时间减少。两者叠加形成的 $R_i(t_i)$ 总风险曲线上存在一个最小值点，该点对应的的时间即为最优检测时点。

8.2 风险函数的数学构建

为量化延迟检测的健康风险，依据题目描述的早、中、晚三个孕期风险等级，构建了一个分段函数。该函数通过线性和指数部分描述风险增长先缓后急的特征

$$R_{late}(t_i) = \begin{cases} \frac{2}{14}(t_i - 70) & \text{若 } 70 \leq t_i \leq 84 \\ 2 + \frac{4}{105}(t_i - 84) & \text{若 } 84 < t_i \leq 189 \\ 0.2225 \cdot e^{0.0243 \cdot t_i} & \text{若 } 189 < t_i \leq 210 \end{cases} \quad (23)$$

在此函数中， $R_{late}(t_i)$ 代表在第 t_i 天检测时，因延迟累积的健康风险值，自变量 t_i 为天数。

对于检测失败的风险，本文使用了微观经济学中的机会成本理论进行量化。选择在特定时点检测，若因 Y 染色体浓度不达标而失败，其后果是必须延后进行下一次检测。此延后构成一种机会成本，其代价是在等待重新检测期间，孕妇所承受的额外健康风险增量。因此，检测失败风险 $R_{fail}(t_i)$ 被定义为失败概率与失败所致机会成本的乘积

$$R_{fail}(t_i) = E[P_{fail,group}(t_i)] \times W(t_i) \times [R_{late}(t_i + \Delta t) - R_{late}(t_i)] \quad (24)$$

其中， $E[P_{fail,group}(t_i)]$ 是该分组在时点 t_i 的期望失败概率。 $W(t_i)$ 是随时间变化的价值权重函数。 Δt 代表两次检测的时间间隔，本文设定为 14 天。最后的差值项是对机会成本的量化，表示因本次检测失败而被迫推迟 Δt 天后，带来的健康风险净增量。

时间价值权重 $W(t_i)$ 用以体现不同孕周决策价值的差异，其形式为一个反向逻辑斯谛函数

$$W(t_i) = 0.01728 + \frac{0.16344}{1 + e^{0.1(t_i - 154)}} \quad (25)$$

此函数中变量 t_i 为检测时点的天数，函数输出值 $W(t_i)$ 为该时点对应的决策价值权重。

8.3 失败概率的预测模型

为计算特定分组在特定时间的期望失败概率 $E[P_{fail,group}(t_i)]$ ，需要一个能够预测 Y 染色体浓度的数学模型。该模型需能反映群体趋势与个体差异。本文采用问题一建立的非线性混合效应模型进行预测。模型形式为

$$\hat{Y}_{ij} = (\beta_0 + u_{0,i}) + (\beta_1 + u_{1,i})GW_{ij} + \beta_2 GW_{ij}^2 + \beta_3 GW_{ij}^3 + \beta_4 BMI_{ij}^3 \quad (26)$$

其中， $\hat{Y}_{ij}$ 是对第 i 位孕妇在第 j 次检测时 Y 染色体浓度的预测值。参数 β_0 至 β_4 是固定效应系数，代表样本总体的平均变化规律。 $u_{0,i}$ 与 $u_{1,i}$ 是随机效应项，代表第 i 位孕妇的个体基线水平与孕周影响的个体差异。

基于此模型，可计算任一孕妇 i 在未来时间点 t 的失败概率。检测失败定义为 Y 染色体浓度低于百分之四的阈值。个体失败概率 $P_{fail,i}(t)$ 的计算用到模型的预测值 $\hat{Y}_i(t)$ 与模型残差的标准差 $\hat{\sigma}_\epsilon$ ，其计算式为

$$P_{fail,i}(t) = P(Y_i(t) < 0.04) = \Phi\left(\frac{0.04 - \hat{Y}_i(t)}{\hat{\sigma}_\epsilon}\right) \quad (27)$$

其中 $\Phi(\cdot)$ 是标准正态分布的累积分布函数。一个分组的整体期望失败概率，是该分组内所有个体失败概率的算术平均值

$$E[P_{fail,group}(t)] = \frac{1}{n_{group}} \sum_{i \in group} P_{fail,i}(t) \quad (28)$$

此处的 n_{group} 是该分组内的孕妇总人数。该计算方法将每位孕妇的个体特征都纳入考量，从而得到整个群体的风险评估。图 17 展示了混合效应模型为部分孕妇生成的 Y 染色体浓度达标概率预测曲线，体现了模型捕捉到的个体间差异。




图 17 混合效应模型预测的个体 Y 染色体浓度达标概率变化轨迹

8.4 模型求解与最优方案确定

模型的求解采用 K 均值聚类与网格搜索结合的双层优化算法。外层循环遍历分组数 K 从 2 至 8。对每个 K 值，先对所有样本的 BMI 进行 K 均值聚类以完成分组。随后在内层优化中，对每个组别，在 70 天至 196 天的时间范围内进行网格搜索，逐日计算其总期望风险，取风险最低点对应的的时间作为该组的最佳 NIPT 时点。最后，比较不同 K 值下的加权平均总风险，风险最低者对应的 K 值即为最优分组数。




图 18 不同分组数 K 对应的加权平均总风险

选择最优分组数的过程如图 18所示。图中以柱状图形式展示了不同分组数 K 对应的加权平均总风险值。计算结果表明，当分组数 K 等于 7 时，加权平均总风险达到所有候选方案中的最小值 4.0656。因此，将孕妇群体划分为七个组别是当前模型下的最优策略。




图 19 最优分组数 K 等于 7 时基于 BMI 的聚类结果

在确定最优分组数为 7 后，对孕妇 BMI 进行聚类的结果可见于图 19。该图以散点形式展示了每一个样本，并用不同颜色标识其所属的群组。七个群组沿孕妇 BMI 轴向分布，形成了七个相互邻接的区间，体现了对孕妇群体的细分。




图 20 最优分组方案下各群组的期望风险曲线

各群组的最佳检测时点由其总期望风险曲线确定，如图 20所示。图中每条曲线代表一个 BMI 群组的总期望风险随检测孕周的变化。所有曲线初期均呈现下降趋势，之后转为上升。曲线的最低点即为该群组风险最小化的最佳检测时点。一个主要趋势是，随着孕妇 BMI 的升高，风险曲线的最低点向更晚的孕周移动。

表 6 最优分组方案与 NIPT 时点建议

群组	BMI 范围	孕妇数量	最佳时点 (周)
群组 1	[20.70, 20.70]	4	10.0
群组 2	[26.62, 29.90]	197	12.86
群组 3	[29.93, 31.84]	300	13.29
群组 4	[31.88, 33.98]	260	12.29
群组 5	[34.01, 36.70]	163	15.71
群组 6	[36.79, 41.13]	64	22.43
群组 7	[41.52, 46.88]	10	16.43

最终的分组方案与各组别的最佳 NIPT 时点建议在表 6中进行了总结。该表明确了每个群组的 BMI 取值范围与孕妇数量。核心结果体现在最佳时点列，数据显示出 BMI 与最佳时点的正向关联。BMI 最低的群组 1，其最佳检测时点为孕 10 周。BMI 较高的群组 6，其最佳检测时点则推迟至孕 22.43 周。此结果为不同 BMI 的孕妇群体提供了差异化的 NIPT 检测时间窗口。

8.5 模型稳定性分析

为检验模型结论的稳定性，本文从参数敏感性与检测阈值两个维度进行分析。




图 21 机会成本时间延迟 Δt 的敏感性分析

机会成本中的时间延迟参数 Δt 对结果的影响如图 21所示。在保持其他参数不变的条件下，调整 Δt 在 14 天至 28 天的范围内变动。随着时间延迟 Δt 的增加，即检测失败的代价变高，多数群组的最佳检测时点均一致性地向更早的孕周移动。此结果符合决策逻辑，当失败后果更严重时，模型会选择一个更早的时间点以降低失败概率。




图 22 Y 染色体浓度阈值对最佳检测时点的影响分析

为分析 NIPT 技术标准变化对最优时点策略的影响，本文分析了 Y 染色体浓度阈值

的变动。图 22展示了当浓度阈值在 3.5% 至 4.5% 之间变化时，各组最佳检测时点的变化。随着检测阈值的提高，即成功标准更为严格，各组的最佳检测时点均呈现出系统性的推迟。这表明当检测标准更高时，模型会建议一个更保守的策略，通过适当延长等待时间，来换取 Y 染色体浓度超过阈值的更高把握。

参考文献

- [1] 张亮亮, 卓召振, 黄盛文, 任凌雁, 牟静, and 匡颖. 贵州省多中心 16798 例 nipt-plus 结果回顾性分析. 贵州医药, 49(08):1296–1299, 2025.
- [2] 张鹏, 莫伟英, 蒙明慧, and 张红燕. 无创产前检测对性染色体非整倍体检出情况的影响及相关伦理思考. 中国临床新医学, 18(06):690–695, 2025.
- [3] 钟佳通, 胡亮, 温丽娟, 李双武, 陈晓杭, 裴元元, and 刘维强. 双胎妊娠中无创产前检测的胎儿游离 dna 浓度特征及检测失败原因分析. 中国产前诊断杂志 (电子版), 15(03):25–30, 2023.
- [4] 蒋丽雅, 卢劭侃, 杜佳恩, 陈阔阔, 张思恬, 伍圣洁, 柳天玉, and 叶佳昊. 无创产前检测技术的发展与应用. 临床医学研究与实践, 10(23):191–194, 2025.